西南财经大学

Southwestern University of Finance and Economics

课程论文

学年学期：2022-2023

课程名称：python 数据分析

论文题目：成都市二手房房价分析与预测

学生学号：42123030

学生姓名：邓智滨

学　　院：管理科学学院

班　　级：周四晚 10、11、12 节

评语：

得　分：

评阅教师签字：　　年　　月

目录

目录 2
1.摘要 3
2.背景、意义 3
2.1 背景 3
2.2 意义 4
3.数据分析流程 5
3.1 数据爬取 5
3.2 数据预处理 7
3.3 可视化分析 8
3.4 模型选择和拟合 19
3.4.1 数据处理 19
3.4.2 评价指标 20
3.4.3 模型拟合及评价 22
4.实验结果 27
5.不足和改进 29
5.1 不足 29
5.2 改进 30
6.总结 31

1.摘要

本报告是一个基于成都市二手房数据进行分析与建模，以预测其二手房房价的 Python 数据分析报告。报告采用 Python 爬虫技术爬取链家网上成都市的二手房相关数据，利用 Python 编程技术对其进行相关数据处理操作，并对数据的内容、相关度、分布规律等等通过可视化方法进行分析。然后，在进一步处理好的数据中选择一些变量，通过线性回归模型、K 近邻模型、决策树模型、随机森林模型四个模型来拟合预测房价，并通过相关评估指标评估各模型的拟合效果。我们发现随机森林模型相对于其他三个模型而言，其预测效果最为理想。最后，我们对整个数据分析实验进行了更全面的考虑和相关总结。

2.背景、意义

2.1 背景

1. 随着近年来我国二手房交易量的不断增加，二手房市场已经成为房地产市场的重要组成部分。二手房价格的变动不仅影响着购房者的决策，也是房地产投资者重点关注的因素，其价格变化关系到房地产行业发展和人们居住成本。因此，准确预测二手房价格走势及其影响因素，对各方都具有重要意义。

2. 目前我国二手房交易活跃，价格水平较高，部分城市二手房价格上涨压力较大，存在价格泡沫的风险。如何理清二手房价格变化规律和预测趋势，对稳定房地产市场具有重要意义。

3. 互联网数据和机器学习技术的发展为二手房价格预测提供了新思路。通过爬取和分析二手房交易网站数据，可以建立数据驱动的二手房价格预测模型。

4. 同时，成都市是我国较早实行住房制度改革的城市之一，二手房市场活

跃,交易数据丰富,非常适合进行二手房价格研究与预测。

2.2 意义

1. 准确预测二手房价格走势,可以为购房者和投资者在二手房市场做出正确决策提供信息支撑,实现资源优化配置。

2. 为政府部门制定管控二手房市场的政策提供数据支撑。有助于理顺二手房价格走势,防范价格泡沫。

3. 基于二手房交易网站大数据建立的预测模型,可以广泛用于各个城市二手房市场分析与预测。为不同参与方提供判断依据。

4. 二手房价格预测作为机器学习和数据采集技术应用的案例,可以丰富相关技术的实践经验和研究成果。探索数据采集和建模的新思路。

5. 二手房价格分析技能的提高,为其他互联网数据采集和建模应用提供借鉴。推动数据科学和机器学习技术的发展。

本研究运用数据科学的方法对二手房交易信息进行分析与建模,在一定程度上实现了交易数据的价值挖掘与商业化应用。这为房地产企业大数据与算法应用提供了参考,也为相关研究者进行二手房价格分析与预测提供了借鉴,具有一定的理论与实践意义。

报告最终得出二手房价格预测结果及其影响分析,为购房与投资决策提供商业价值。准确预测未来房价变动趋势,对于房地产市场各方都具有重要作用。本研究选取该城市二手房数据进行建模预测,虽然结果仅代表该城市一定时期内的房价走势,但所采用的数据科学方法具有较好的普适性,可为其他城市二手房价格分析与预测提供参考。

3.数据分析流程

3.1 数据爬取

图 3. 1. 1

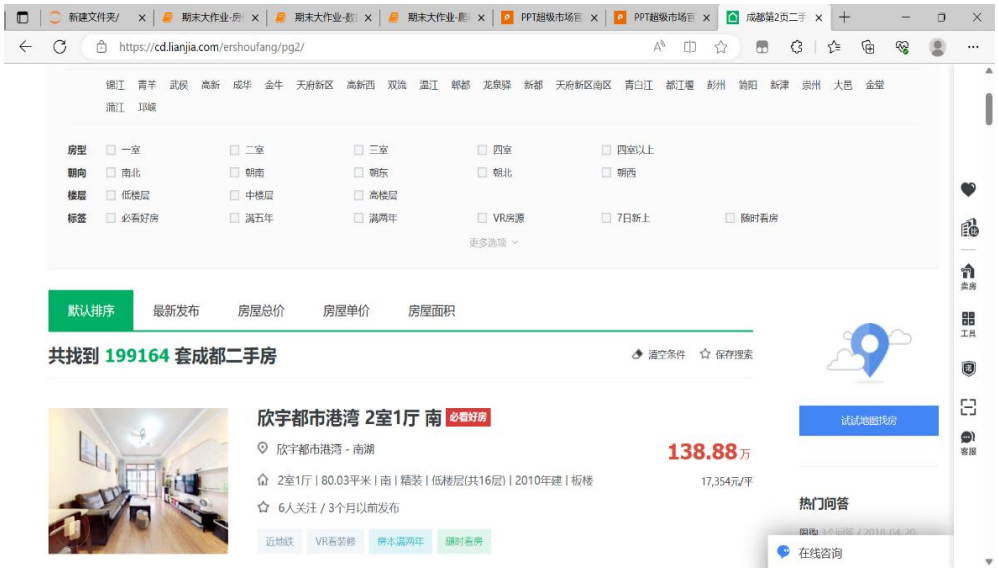

图 3. 1. 2

图 3. 1. 3

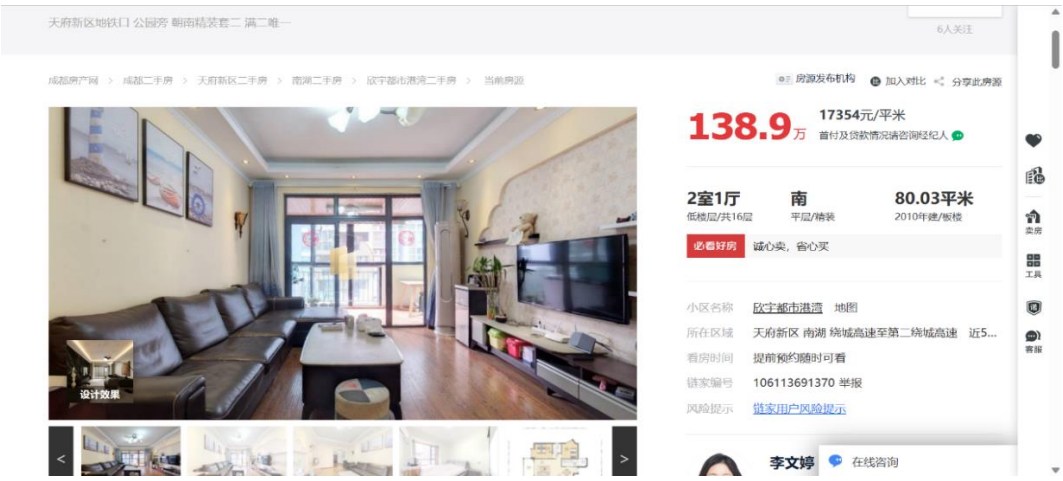

图 3.1.4

基本信息

基本属性				
	房屋户型	2室1厅1厨1卫	所在楼层	低楼层 (共16层)
	建筑面积	80.03㎡	户型结构	平层
	套内面积	暂无数据	建筑类型	板楼
	房屋朝向	南	建筑结构	钢混结构
	装修情况	精装	梯户比例	两梯四户
	配备电梯	有		

交易属性				
	挂牌时间	2023-02-28	交易权属	商品房
	上次交易	2020-11-26	房屋用途	普通住宅
	房屋年限	满两年	产权所属	共有
	抵押信息	有抵押 90万元 客户偿还	房本备件	已上传房本照片
	房源核验码	106113691370	有效期限	2023.02.28-2024.02.23

特别提示：本房源所示信息仅供参考，购房时请以该房屋档案登记信息、产权证信息以及所签订合同条款约定为准；本房源公示信息不做为合同条款，不具有合同约束力。

我所爬取的网站为链家网，如图 3.1.1 所示。所爬取数据内容大致为图 3.1.2 至图 3.1.4 中所对应的相关内容。先将每个二手房的基本数据和对应网址进行爬取，我们将得到二手房的标题信息、基本信息、总价、均价以及其对应的网址，如图 3.1.5 中所示。再通过每个二手房所对应的网址链接继续爬取其进一步的信息，最终我们会得到二手房的标题信息、基本信息、总价、均价、网址、梯户比、是否配备电梯以及所在地区，如图 3.1.6 所示。

图 3.1.5

In [216]:
```
Houses
```

Out[216]:

	标题	信息	总价	均价	网址
0	银泰花园 9室2厅 南 北	9室2厅 | 375.39平米 | 南 北 | 简装 | 低楼层(共3层) | 2010年建...	445万	11,855元/平	https://cd.lianjia.com/ershoufang/106114646272...
1	优客联邦一期 2室1厅 西南	2室1厅 | 79.17平米 | 西南 | 精装 | 低楼层(共16层) | 2010年建 ...	160万	20,210元/平	https://cd.lianjia.com/ershoufang/106113739659...
2	溢阳绿城 3室1厅 南	3室1厅 | 86.62平米 | 南 | 简装 | 低楼层(共6层) | 2002年建 | 板楼	154万	17,779元/平	https://cd.lianjia.com/ershoufang/106102366412...
3	东山国际新城D区 3室2厅 东南	3室2厅 | 89.6平米 | 东南 | 简装 | 低楼层(共11层) | 2011年建 |...	109.8万	12,255元/平	https://cd.lianjia.com/ershoufang/106114727946...
4	杜鹃城 4室2厅 东南	4室2厅 | 138平米 | 东南 | 精装 | 6层 | 2017年建 | 板楼	66万	4,783元/平	https://cd.lianjia.com/ershoufang/106114693493...
...	...	...	...	...	...
4500	二十一世纪花园一期 4室2厅 南	4室2厅 | 122.56平米 | 南 | 简装 | 中楼层(共8层) | 2003年建 | 板楼	220万	17,951元/平	https://cd.lianjia.com/ershoufang/106114763013...
4501	鹭岛国际四期 2室1厅 东南	2室1厅 | 87.83平米 | 东南 | 精装 | 中楼层(共18层) | 2012年建 ...	220万	25,049元/平	https://cd.lianjia.com/ershoufang/106114762982...
4502	西林豫府B区 2室1厅 南	2室1厅 | 76.43平米 | 南 | 毛坯 | 中楼层(共11层) | 2000年建 | 板楼	85万	11,122元/平	https://cd.lianjia.com/ershoufang/106114762952...
4503	中莲池横街8号 2室2厅 南 北	2室2厅 | 80.31平米 | 南 北 | 其他 | 低楼层(共6层) | 1989年建 ...	240万	29,885元/平	https://cd.lianjia.com/ershoufang/106114762943...
4504	蓝光花满庭一期 2室1厅 东北	2室1厅 | 71.23平米 | 东北 | 简装 | 高楼层(共21层) | 2009年建 ...	118万	16,567元/平	https://cd.lianjia.com/ershoufang/106114762884...

4505 rows × 5 columns

图 3.1.6

Out[347]:

	标题	信息	总价	均价	网址	梯户比	是否有电梯	地区
0	银泰花园 9室2厅 南 北	9室2厅 | 375.39平米 | 南 北 | 简装 | 低楼层(共3层) | 2010年建...	445万	11,855元/平	https://cd.lianjia.com/ershoufang/106114646272...	一梯一户	无	双流
1	优客联邦一期 2室1厅 西南	2室1厅 | 79.17平米 | 西南 | 精装 | 低楼层(共16层) | 2010年建 ...	160万	20,210元/平	https://cd.lianjia.com/ershoufang/106113739659...	两梯八户	有	武侯
2	溢阳绿城 3室1厅 南	3室1厅 | 86.62平米 | 南 | 简装 | 低楼层(共6层) | 2002年建 | 板楼	154万	17,779元/平	https://cd.lianjia.com/ershoufang/106102366412...	两梯两户	有	武侯
3	东山国际新城D区 3室2厅 东南	3室2厅 | 89.6平米 | 东南 | 简装 | 低楼层(共11层) | 2011年建 |...	109.8万	12,255元/平	https://cd.lianjia.com/ershoufang/106114727946...	一梯四户	有	龙泉驿
4	杜鹃城 4室2厅 东南	4室2厅 | 138平米 | 东南 | 精装 | 6层 | 2017年建 | 板楼	66万	4,783元/平	https://cd.lianjia.com/ershoufang/106114693493...	一梯两户	暂无数据	郫都
...	...	...	...	...	...	...	...	...
4500	二十一世纪花园一期 4室2厅 南	4室2厅 | 122.56平米 | 南 | 简装 | 中楼层(共8层) | 2003年建 | 板楼	220万	17,951元/平	https://cd.lianjia.com/ershoufang/106114763013...	一梯两户	有	青羊
4501	鹭岛国际四期 2室1厅 东南	2室1厅 | 87.83平米 | 东南 | 精装 | 中楼层(共18层) | 2012年建 ...	220万	25,049元/平	https://cd.lianjia.com/ershoufang/106114762982...	两梯六户	有	武侯
4502	西林豫府B区 2室1厅 南	2室1厅 | 76.43平米 | 南 | 毛坯 | 中楼层(共11层) | 2000年建 | 板楼	85万	11,122元/平	https://cd.lianjia.com/ershoufang/106114762952...	一梯四户	暂无数据	成华
4503	中莲池横街8号 2室2厅 南 北	2室2厅 | 80.31平米 | 南 北 | 其他 | 低楼层(共6层) | 1989年建 ...	240万	29,885元/平	https://cd.lianjia.com/ershoufang/106114762943...	一梯两户	无	锦江
4504	蓝光花满庭一期 2室1厅 东北	2室1厅 | 71.23平米 | 东北 | 简装 | 高楼层(共21层) | 2009年建 ...	118万	16,567元/平	https://cd.lianjia.com/ershoufang/106114762884...	两梯八户	有	金牛

4493 rows × 8 columns

3.2 数据预处理

接下来我们将对图 3.1.6 中的表格进行一些相关的处理。由于我们在爬取数据时已经进行过空值删除的处理，因此在这一步我们所得的数据已经没有空数据的出现。因此我们直接对其进行去重处理，将重复一样的数据进行删除保留一个。由于网址数据对我们后续的分析没有用，我们直接删除这一列。对于总价为“暂无数据”的数据直接将该列数据进行删除，对于是否配备电梯出现“暂无数据”的情况，其出现情况较少，我们假定其为无电梯，并进一步将有无转化为 1 和 0 的数据形式。对于基本信息部分，我们用到 split 方法处理，将基本信息中各类信息提取出来，形成新的列，对于新的列我们也进一步进行一系列数据处理。对于梯户比信息我们将其转化为数值型的比率、户数、梯数。对于有单位的数据部分，我们删除其单位，并将其转化为浮点型数据，便于后续的数据分析。还有等等一系列的数据处理操作，最终我们得到一个表，如图 3.2.1 中所示。

图 3.2.1

Out[49]:

	title	info	totalPrice	avgPrice	eleRate	ifElevator	location	type	area	direct	decorate	floor	date	style	years	ele	host	rate	rooms	hall
1	银泰花园 9室2厅 南 北	9室2厅 | 375.39平米 | 南 北 | 简装 | 低楼层(共3层) | 2010年建...	445.0	11855.0	一梯一户	0	双流	9室2厅	375.3	南 北	简装	低楼层	2010年建	板塔结合	13	1	1	1.0	9	2
2	优客联邦一期 2室1厅 西南	2室1厅 | 79.17平米 | 西南 | 精装 | 低楼层(共16层) | 2010年建 ...	160.0	20210.0	两梯八户	1	武侯	2室1厅	79.1	西南	精装	低楼层	2010年建	板楼	13	2	8	4.0	2	1
3	溢阳绿城 3室1厅 南	3室1厅 | 86.62平米 | 南 | 简装 | 低楼层(共6层) | 2002年建 | 板楼	154.0	17779.0	两梯两户	1	武侯	3室1厅	86.6	南	简装	低楼层	2002年建	板楼	21	2	2	1.0	3	1
4	东山国际新城D区 3室2厅 东南	3室2厅 | 89.6平米 | 东南 | 简装 | 低楼层(共11层) | 2011年建 |...	109.8	12255.0	一梯四户	1	龙泉驿	3室2厅	89.0	东南	简装	低楼层	2011年建	板塔结合	12	1	4	4.0	3	2
5	杜鹃城 4室2厅 东南	4室2厅 | 138平米 | 东南 | 精装 | 6层 | 2017年建 | 板楼	66.0	4783.0	一梯两户	0	郫都	4室2厅	13.0	东南	精装	未知层	2017年建	板楼	6	1	2	2.0	4	2

3.3 可视化分析

接下来，我们将对所处理好的数据做一些可视化的分析。

图 3.3.1

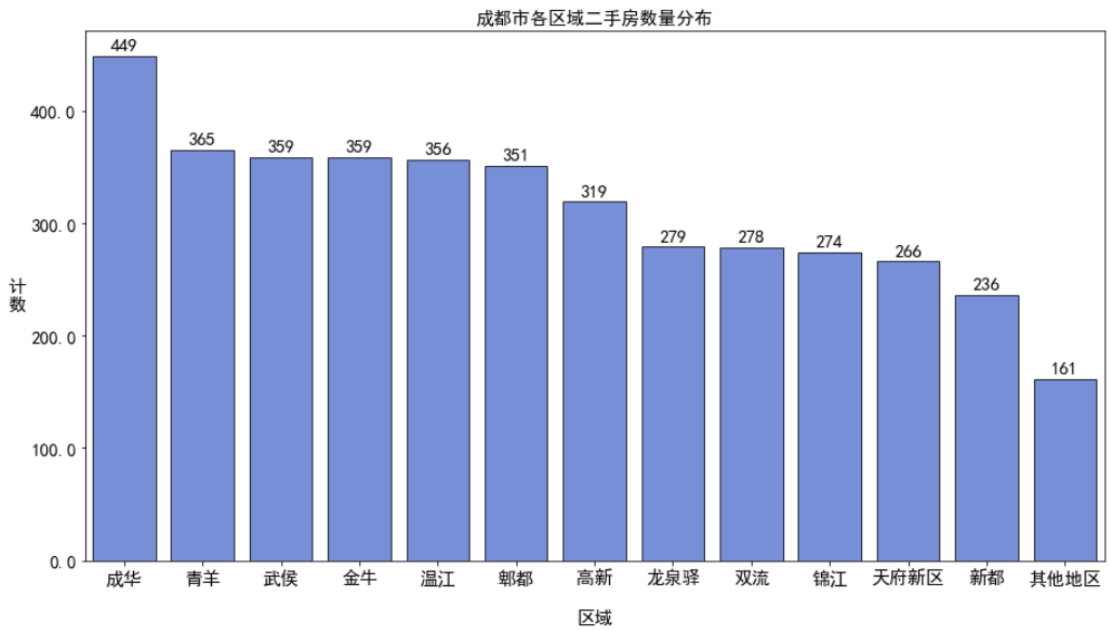

该图是成都市各区域二手房数量分布图，总体来说各区域间二手房数量是相对比较均衡的，只有成华区二手房数量相对来说较多，成都相对偏远地区的二手房数量较少，其他多为两百多、三百多。

图 3.3.2

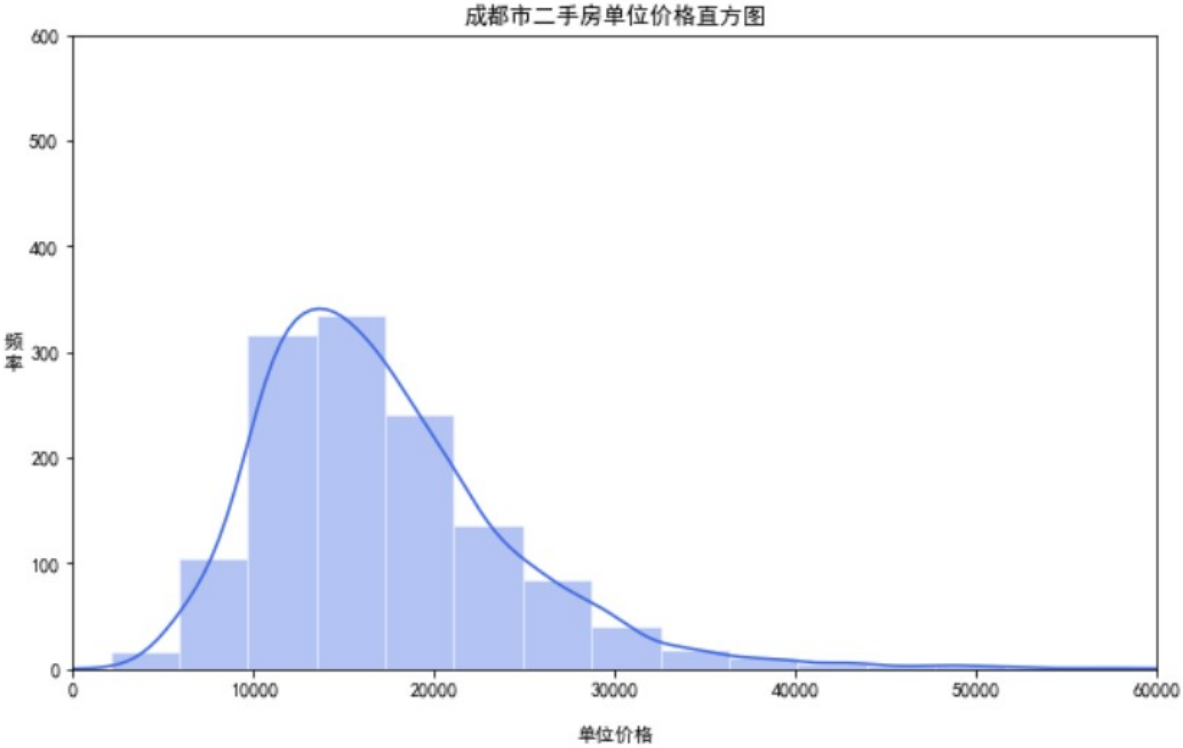
成都市二手房单位价格直方图
频率
单位价格
0
100
200
300
400
500
600
10000
20000
30000
40000
50000
60000

图 3.3.3

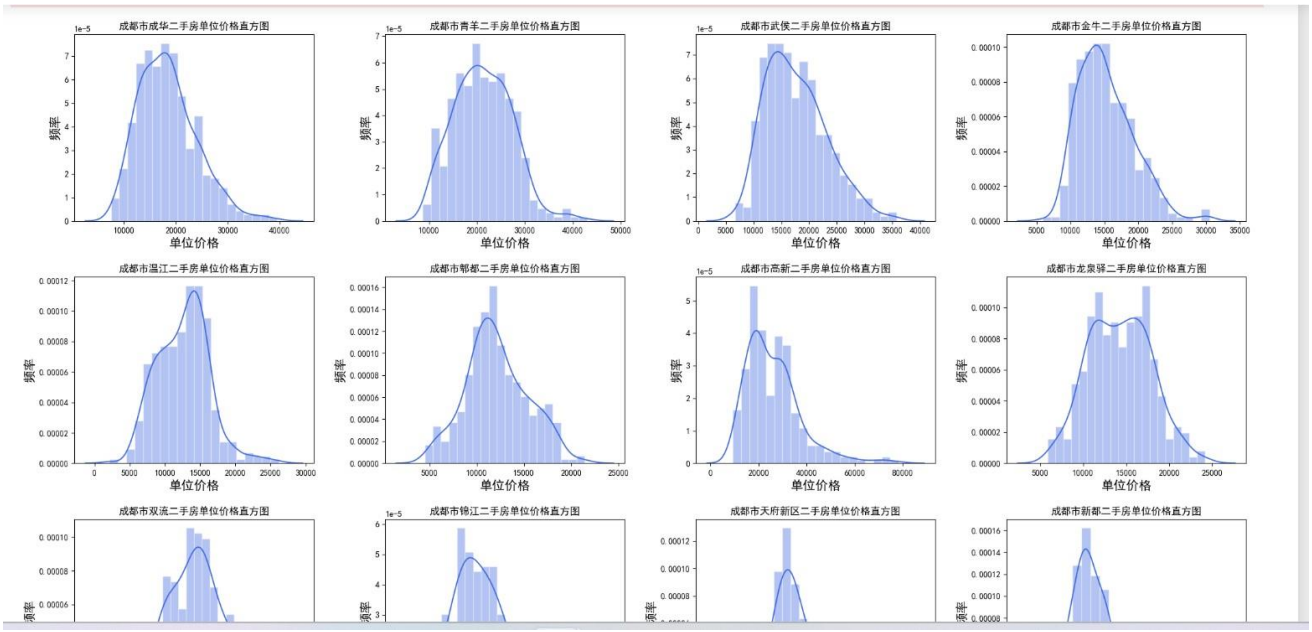
成都市成华二手房单位价格直方图
成都市青羊二手房单位价格直方图
成都市武侯二手房单位价格直方图
成都市金牛二手房单位价格直方图
成都市温江二手房单位价格直方图
成都市郫都二手房单位价格直方图
成都市高新二手房单位价格直方图
成都市龙泉驿二手房单位价格直方图
成都市双流二手房单位价格直方图
成都市锦江二手房单位价格直方图
成都市天府新区二手房单位价格直方图
成都市新都二手房单位价格直方图
频率
单位价格

图 3.3.4

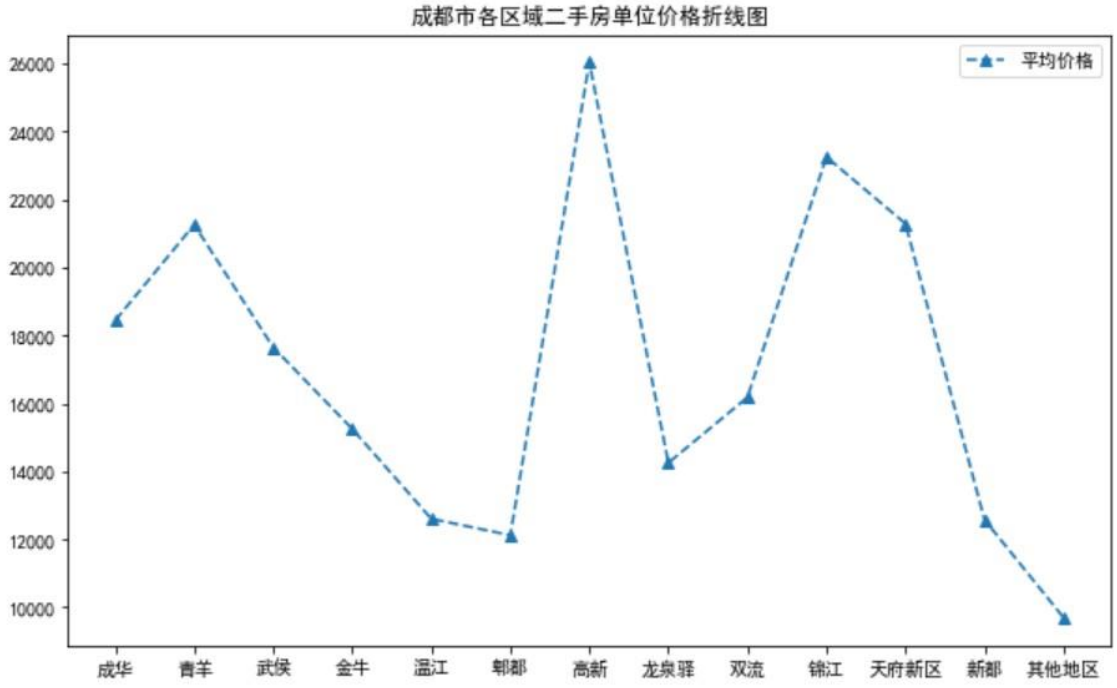

由图 3.3.2 至 3.3.4 从总体来看，成都市二手房单位价格多为 1 万每平方米到 2 万每平方米，从区域来看，高新区二手房平均单位价格最高，约为 26000 左右，其他地区平均单位价格最低，约为 10000 左右。从图 3.3.4 中可以很直观地看出各区域单位价格差别，可供消费者、投资者参考。同样，政府也可根据此来对各地区实施不同的相关房价的政策，如各种补贴或者限制政策，以此管控稳定房价市场，同样可促使各地经济稳定发展。

图 3.3.5

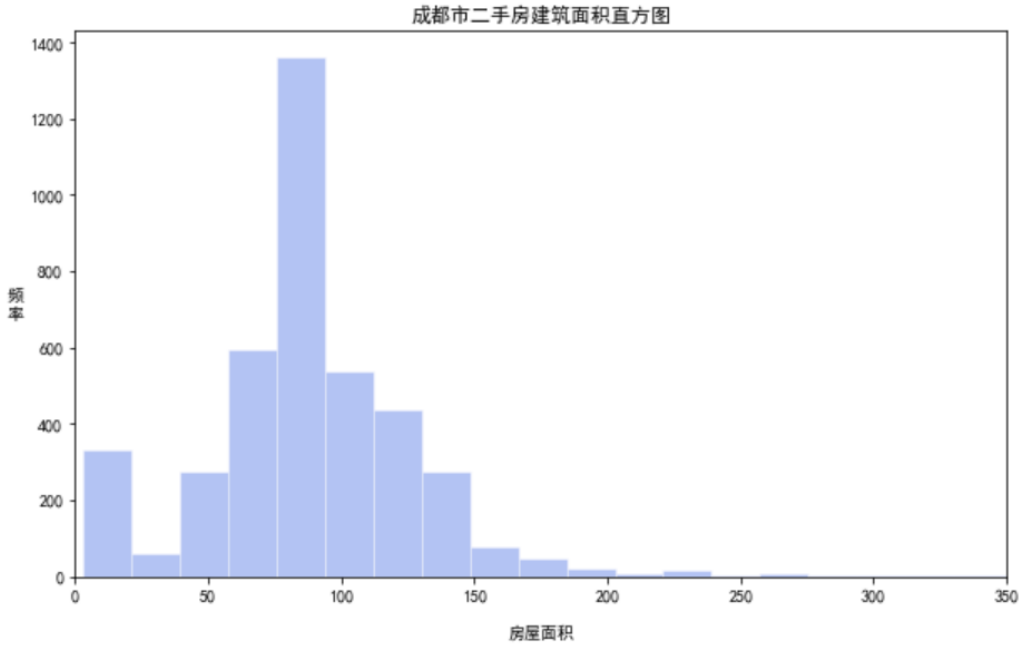

图 3.3.6

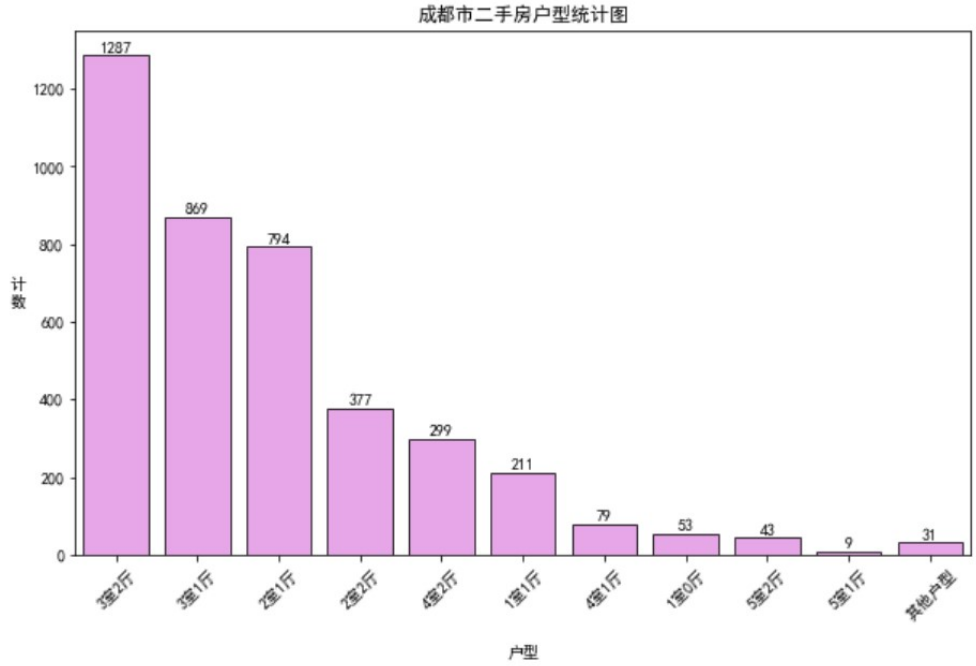

由图 3.3.5 和 3.3.6 可看出成都市二手房面积主要集中在 80 平米左右，同样对应着多为 3 室 2 厅、3 室 1 厅、2 室 1 厅的户型。说明成都市二手房消费市场主要集中于 80 平米这种小户型的二手房，可供二手房供应方提供这一相关信息，同样投资者在投资于房地产市场时可以此作为参考，多购买小户型房地产类型。

图 3.3.7

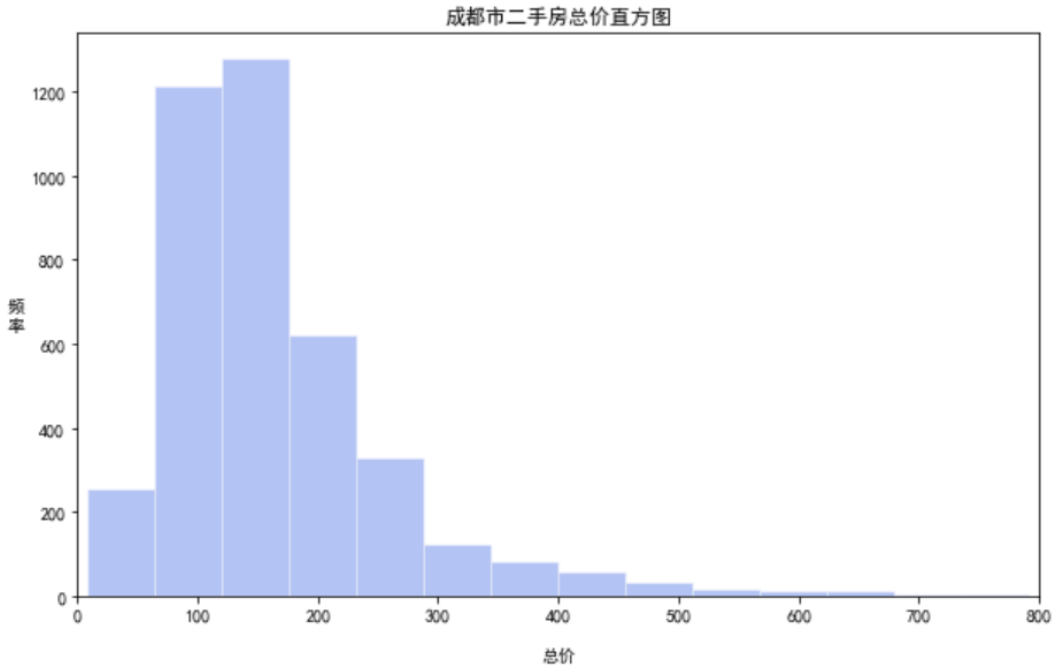
成都市二手房总价直方图
频率
总价

图 3.3.8

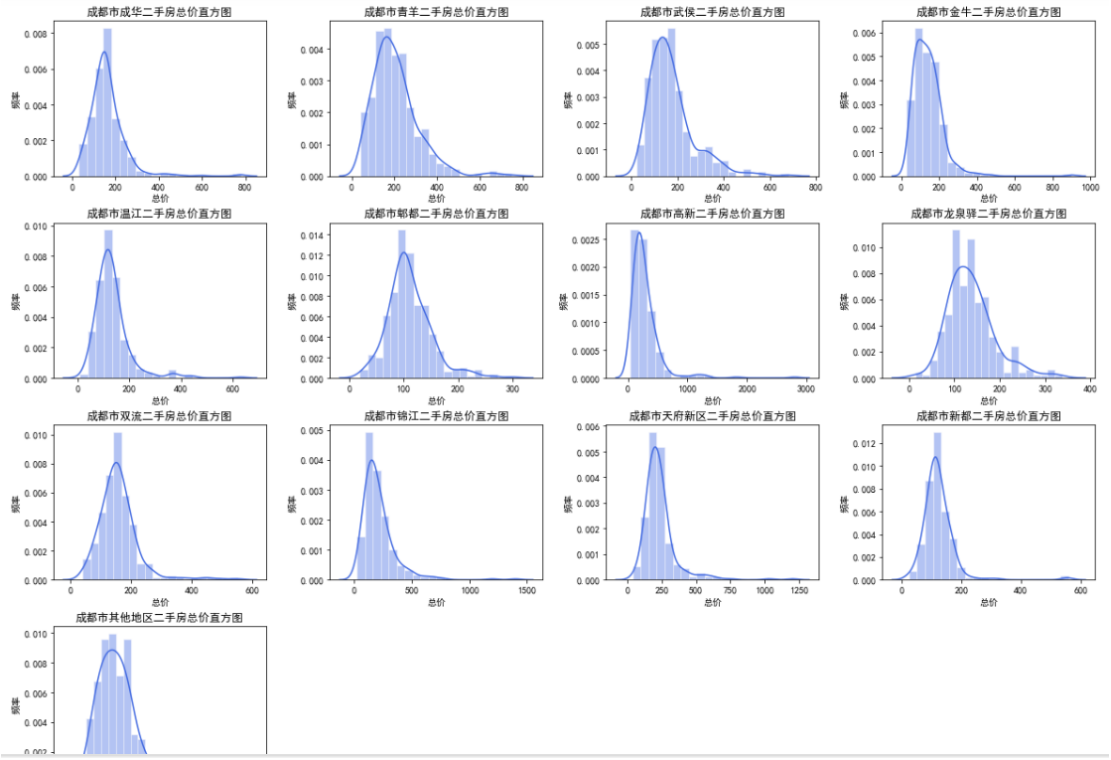
成都市成华二手房总价直方图
成都市青羊二手房总价直方图
成都市武侯二手房总价直方图
成都市金牛二手房总价直方图
成都市温江二手房总价直方图
成都市郫都二手房总价直方图
成都市高新二手房总价直方图
成都市龙泉驿二手房总价直方图
成都市双流二手房总价直方图
成都市锦江二手房总价直方图
成都市天府新区二手房总价直方图
成都市新都二手房总价直方图
成都市其他地区二手房总价直方图
频率
总价

图 3.3.9

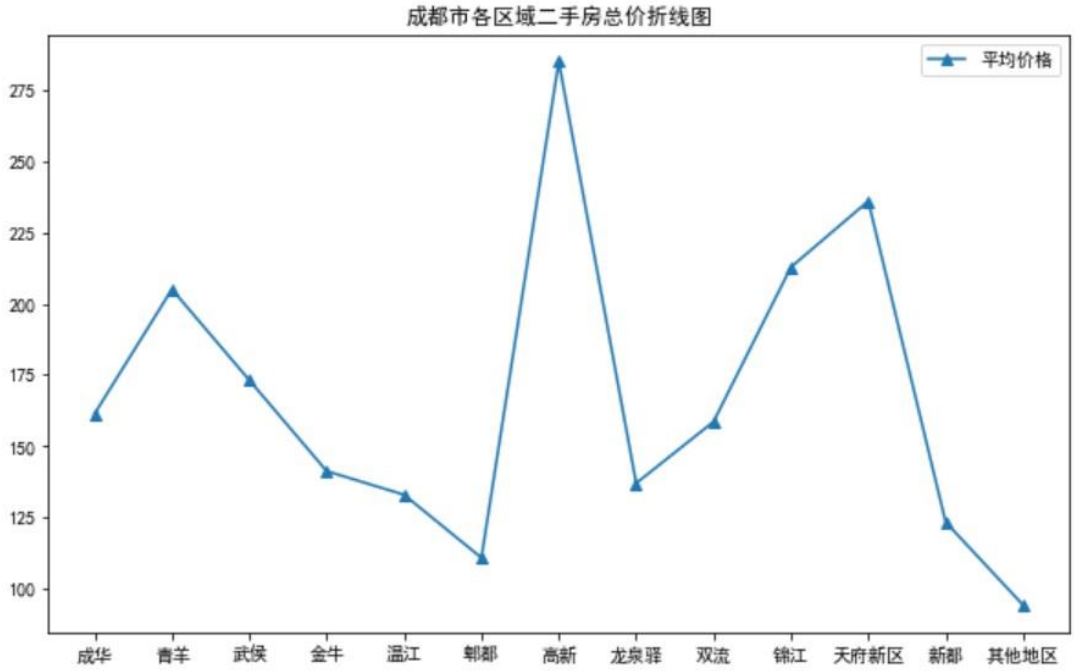

由图 3.3.7 至 3.3.9 从总体看，成都市二手房总价主要在 80 万到 200 万之间，个别地区偏高或偏低，如高新区和天府新区等偏高，其他稍微偏远的地区偏低。图 3.3.9 很直观的给出了各区域的二手房平均总价，可供消费者、投资者来参考，根据自己的预算可简略地对购房区域进行选择。仅靠这一因素是当然不够的，其表示的仅是各地区的均价，而且选房时更要考虑交通、教育等等因素影响。

图 3.3.10

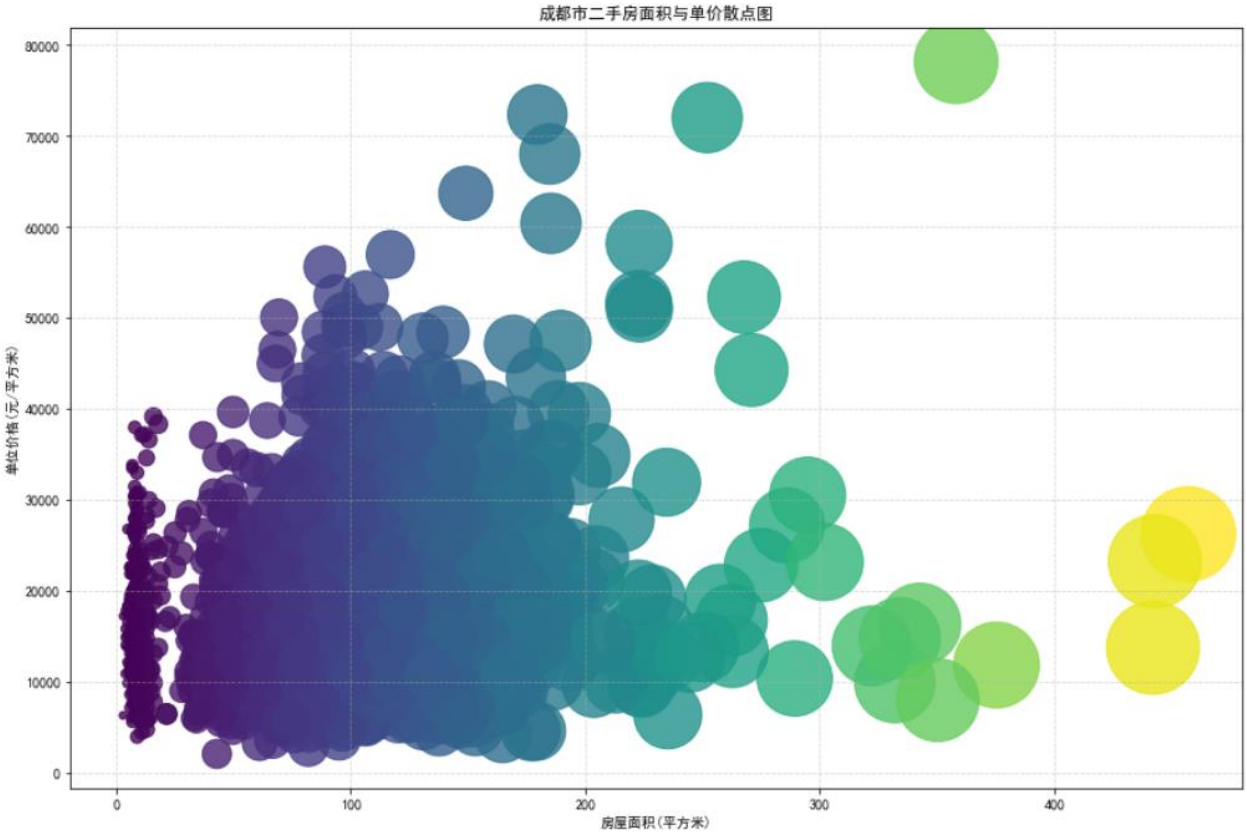
成都市二手房面积与单价散点图
单位价格(元/平方米)
房屋面积(平方米)
0
10000
20000
30000
40000
50000
60000
70000
80000
0
100
200
300
400

图 3.3.11

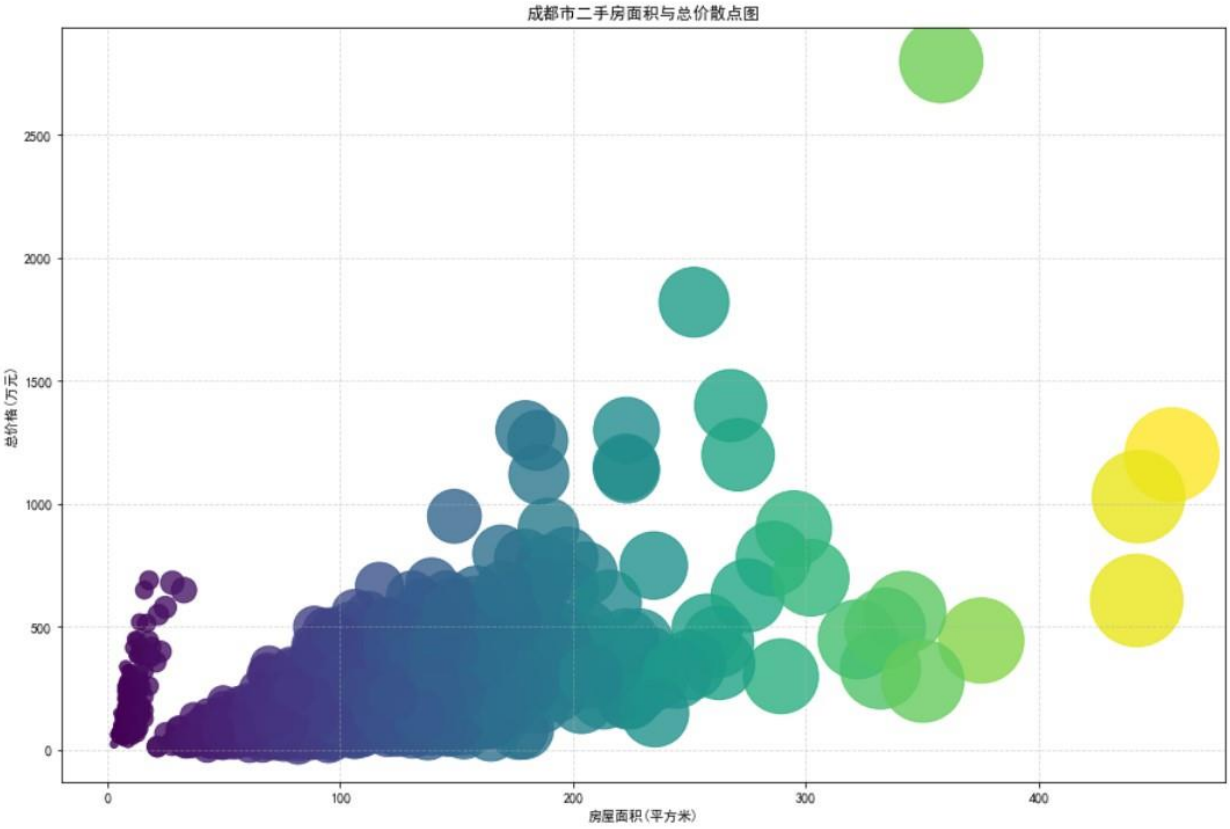
成都市二手房面积与总价散点图
总价格(万元)
房屋面积(平方米)
0
500
1000
1500
2000
2500
0
100
200
300
400

图 3.3.10 和 3.3.11 分别是二手房面积与单价和二手房面积与总价的散点图。由这两个图可看出二手房面积和单价相关性不高，单价应该更多地与地理位置相关，对应的交通、就业、教育等因素相关性更强。总价和面积大致成线性关系，且正相关。

图 3.3.12

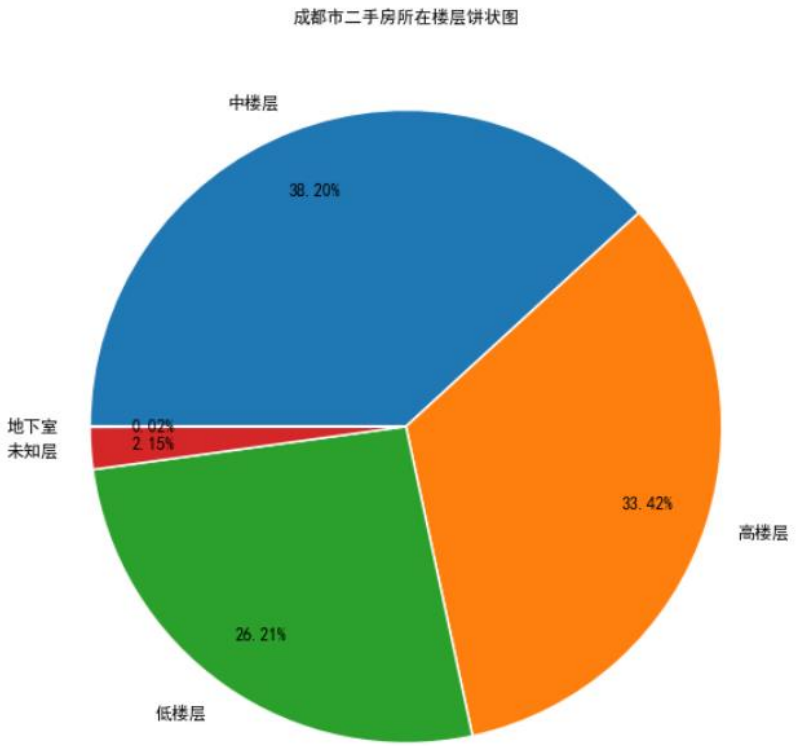

图 3.3.13

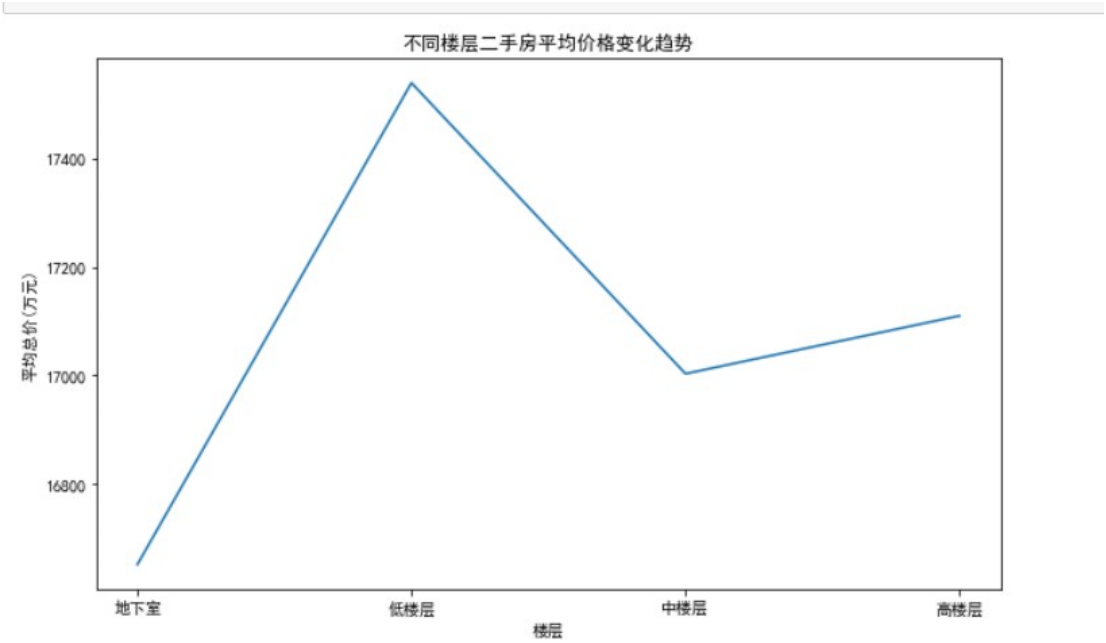

图 3.3.14

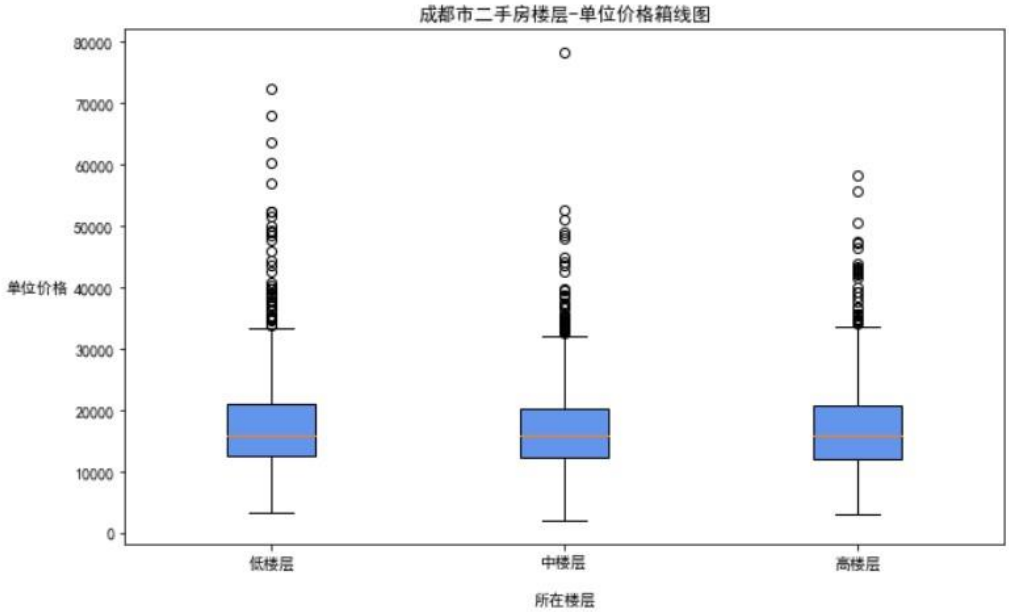

由图 3.3.12 可看出二手房所在楼层相对均衡，中楼层相对偏多一点，低楼层相对偏少。由图 3.3.13 可看出二手房单价与楼层的关系，一般来说，楼层越高单价也会越高，然而在此处低楼层单价明显高于其他楼层，结合图 3.3.14 的楼层单价箱型图，推测多半是由于别墅区的存在，其单价偏高，导致整体低楼层均价也提高明显。由图 3.3.14 中的箱型图可看出各楼层价格波动程度较大，各

楼层价格中位数相差不多。低楼层极值偏多且偏极端，其极端偏大值偏多，影响其均价程度也较大。

图 3.3.15

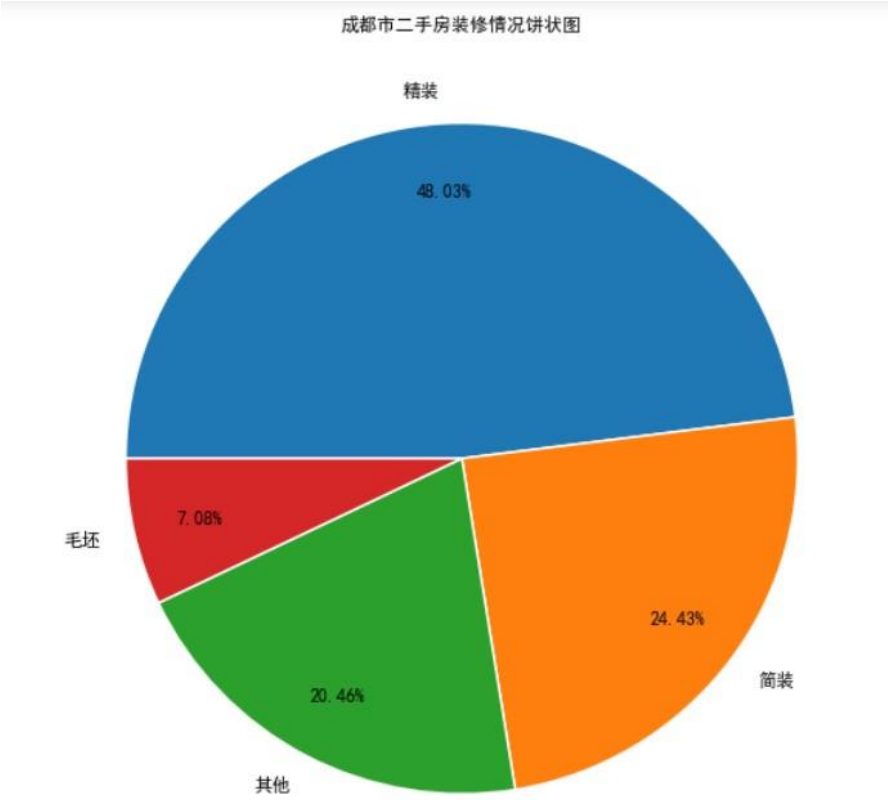

图 3.3.16

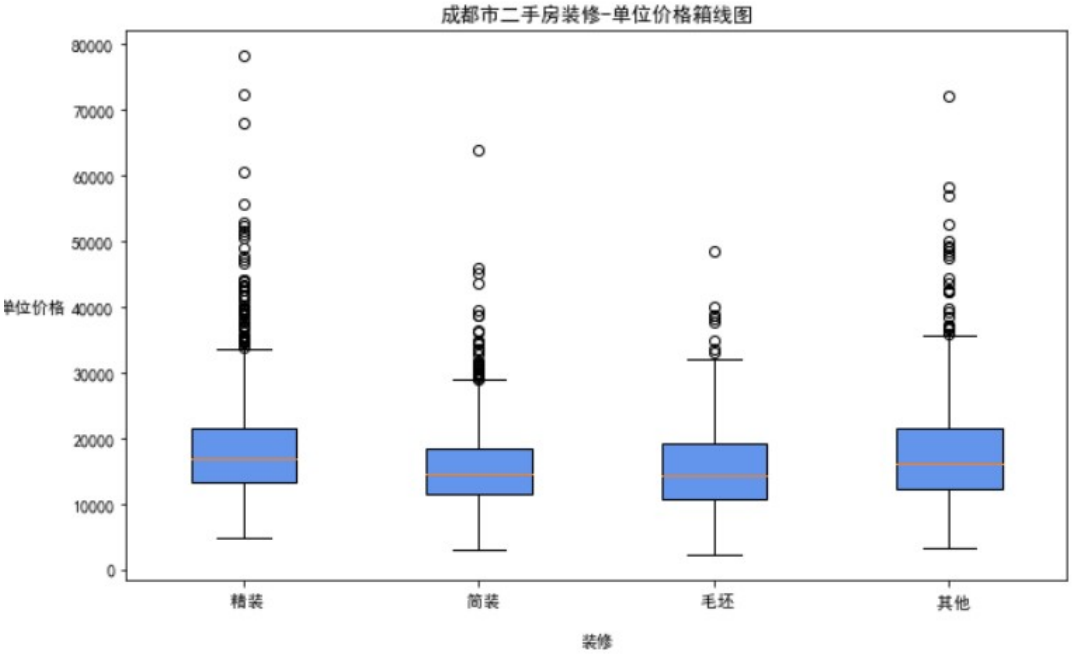

由图 3.3.15 和 3.3.16 可看出成都市二手房约有一半为精装装修，约四分之一为简装，7%为毛坯，说明大部分二手房出售多为居住过后卖出，很少数是直接为毛坯来交易。由图 3.3.16 可看出精装装修会使其单位价格提升，出售方可做好装修来提升房产的价值，当然一定也要考虑到装修的成本。

图 3.3.17

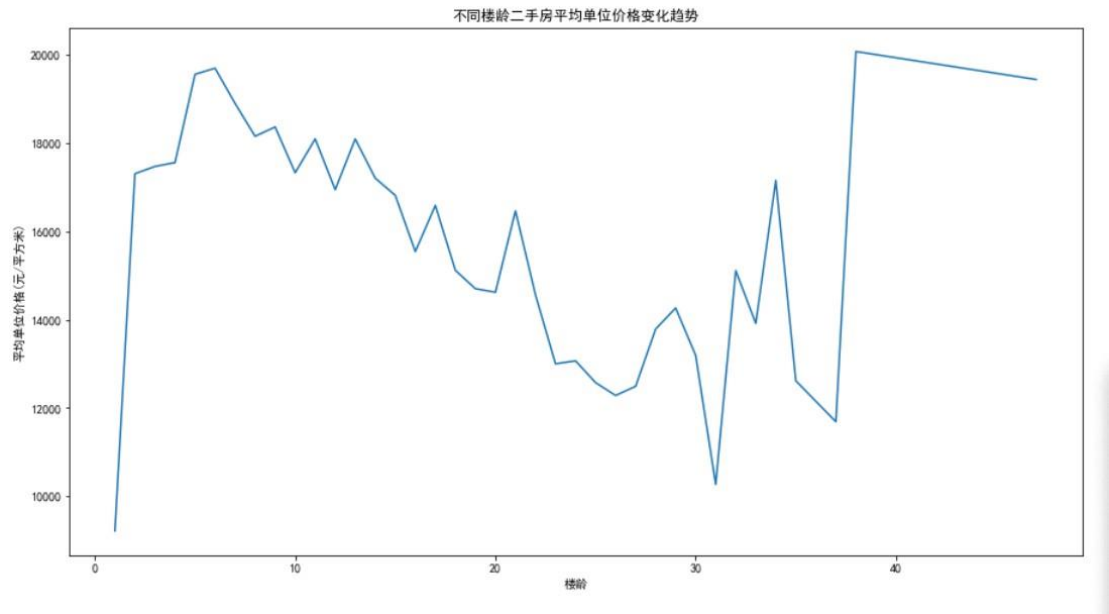

由图 3.3.17 可看出近年新房的二手房房价要偏高，应该是因为其基础设施等各方面相对完善，楼龄稍微偏大的二手房价格一般虽楼龄增加而降低，多半是由于小区设施老化，房屋基本情况比较差，而楼龄进一步增加到三四十岁之后，价格又随楼龄上涨，可能是少数的特殊情况导致，例如某些经济发达交通便利地区的钉子户。也可能是该房可能具有其他价值，如收藏、古董等价值。

图 3.3.18

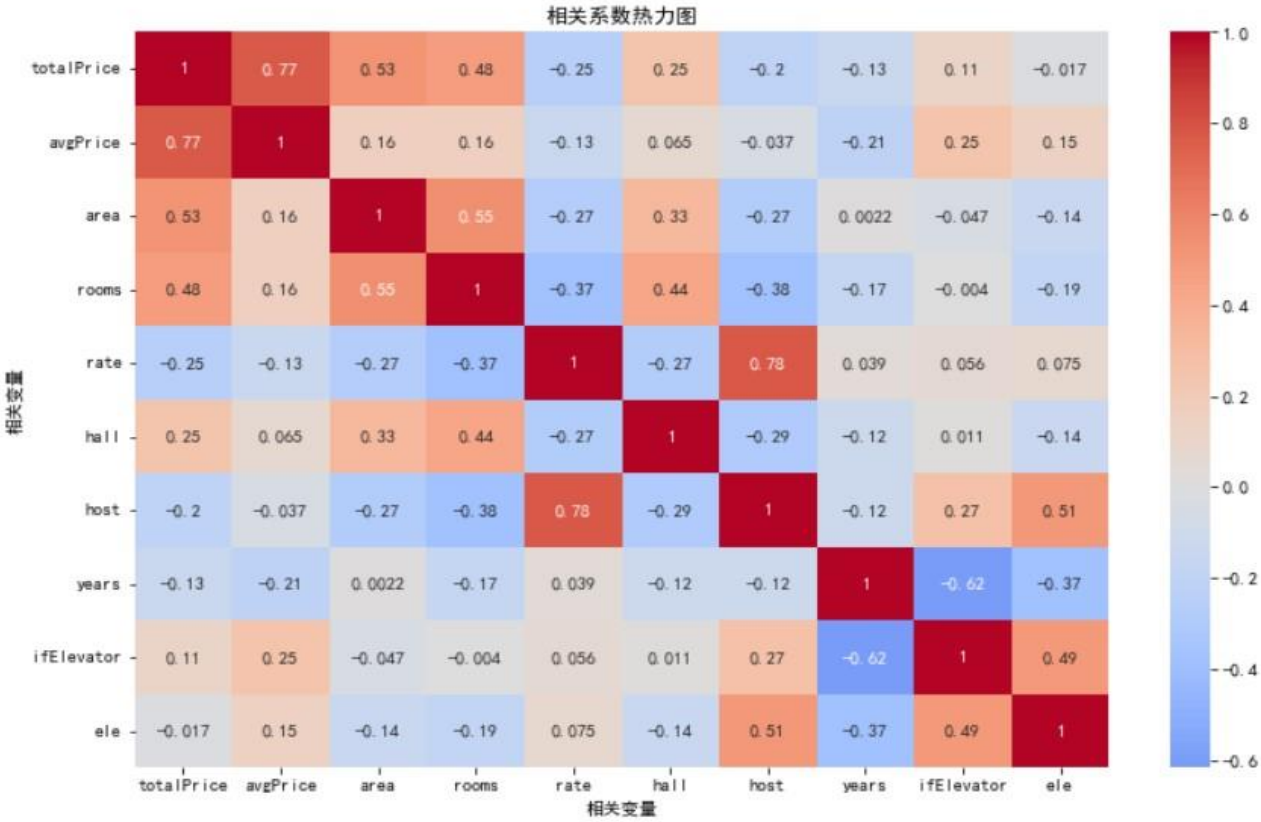

图 3.3.18 是所得各种数据之间的相关系数热力图，可直观的看出各类数据之间的相关性，可看出与总价相关性较强的为均价和面积。

3.4 模型选择和拟合

3.4.1 数据处理

在模型拟合前，我们还对数据进行了进一步的处理，首先选取出我们所需要的数据部分，例如标题部分就可删去。若文字数据能转化成数值型的数据就转化成数值型数据，不便转换的就进行哑变量处理。最终得到了如图 3.4.1、3.4.2 的表。

图 3.4.1.1

totalPrice	avgPrice	ifElevator	area	years	ele	host	rate	rooms	hall	direct_东	direct_东北	direct_东南	direct_其他朝向	direct_北	direct_南	direct_南北	direct_西	direct_西北	direct_西南	decorate其
445.00	11855.0	0	375.3	13	1	1	1.000000	9	2	0	0	0	0	0	0	1	0	0	0	
160.00	20210.0	1	79.1	13	2	8	4.000000	2	1	0	0	0	0	0	0	0	0	0	1	
154.00	17779.0	1	86.6	21	2	2	1.000000	3	1	0	0	0	0	0	1	0	0	0	0	
109.80	12255.0	1	89.0	12	1	4	4.000000	3	2	0	0	1	0	0	0	0	0	0	0	
66.00	4783.0	0	13.0	6	1	2	2.000000	4	2	0	0	1	0	0	0	0	0	0	0	
98.00	14201.0	1	69.0	9	2	5	2.500000	2	2	0	0	0	0	1	0	0	0	0	0	
116.00	13649.0	1	84.9	5	2	6	3.000000	3	1	0	1	0	0	0	0	0	0	0	0	
252.00	20045.0	1	125.7	6	2	5	2.500000	3	2	0	0	0	0	0	1	0	0	0	0	
192.00	15522.0	1	123.0	12	2	4	2.000000	3	1	0	0	0	0	1	0	0	0	0	0	
41.80	5379.0	1	77.7	12	1	6	6.000000	2	1	0	0	1	0	0	0	0	0	0	0	

图 3.4.1.2

decorate_毛坯	decorate_简装	decorate_精装	style_塔楼	style_平房	style_暂无数据	style_板塔结合	style_板楼	location_其他地区	location_双流	location_天府新区	location_成华	location_新都	location_武侯	location_温江	location_郫都	location_金牛	location_锦江
0	1	0	0	0	0	1	0	0	1	0	0	0	0	0	0	0	0
0	0	1	0	0	0	0	1	0	0	0	0	0	1	0	0	0	0
0	1	0	0	0	0	0	1	0	0	0	0	0	1	0	0	0	0
0	1	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
0	0	1	0	0	0	0	1	0	0	0	0	0	0	0	1	0	0
0	0	1	0	0	0	0	1	0	0	0	0	1	0	0	0	0	0
0	0	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	1	1	0	0	0	0	0	0	1	0	0	0	0	0	0	0
0	0	1	1	0	0	0	0	0	0	0	1	0	0	0	0	0	0
0	1	0	1	0	0	0	0	1	0	0	0	0	0	0	0	0	0

数据全部处理完毕后，我们选择通过线性回归模型、K 近邻模型、决策树模型、随机森林模型四个模型来拟合预测总房价。并通过相关评估指标评估各模型的拟合效果。

3.4.2 评价指标

平均绝对误差（MAE）

平均绝对误差的英文全称为 Mean Absolute Error，也称之为 L1 范数损失。是通过计算预测值和真实值之间的距离的绝对值的均值，来衡量预测值与真实值之间的距离。计算公式如下：

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|y_i - f(x_i)|$$

均方误差（MSE）

均方误差英文全称为 Mean Squared Error，也称之为 L2 范数损失。通过计算真实值与预测值的差值的平方和的均值来衡量距离。计算公式如下：

$$MSE = \frac{1}{m}\sum_{i-1}^{m}(f(x_i) - y_i)^2$$

均方根误差（RMSE）

均方根误差的英文全称为 Root Mean Squared Error，代表的是预测值与真实值差值的样本标准差。计算公式如下：

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - f(x_i))^2}$$

决定系数（R2）

决定系数评估的是预测模型相对于基准模型（真实值的平均值作为预测值）的好坏程度。计算公式如下：

$$R^2\left(y_{\text{true}}, y_{\text{pred}}\right) = 1 - \frac{\sum\left(y_{\text{true}} - y_{\text{pred}}\right)^2}{\sum\left(y_{\text{true}} - \bar{y}\right)^2}$$

$$\bar{y} = \frac{1}{n_{\text{samples}}}\sum y_{\text{true}}$$

最好的模型预测的 R2 的值为 1，表示预测值与真实值之间是没有偏差的；

但是最差的模型，得到的 R2 的值并不是 0，而是会得到负值；

当模型的 R2 值为负值，表示模型预测结果比基准模型（均值模型）表现要差；当模型的 R2 值大于 0，表示模型的预测结果比使用均值预测得到的结果要好。

3.4.3 模型拟合及评价

我们将数据集以 3:7 的比列划分为测试集和训练集，y 是总价，其他数据类型作为因变量。接下来就是拟合各个模型，并对其进行评价。

（1） 线性回归模型：

图 3.4.3.1

```
model_LR = LinearRegression()
model_LR.fit(x_train, y_train)
print("params: ", model_LR.get_params())
print("train score: ", model_LR.score(x_train, y_train))
print("test score: ", model_LR.score(x_test, y_test))
predict_y = evaluation(model_LR)
```

```
params:  {'copy_X': True, 'fit_intercept': True, 'n_jobs': None, 'normalize': False, 'positive': False}
train score:  0.7943802033115369
test score:  0.8282162133095595
MAE: 29.64
MSE: 2006.20
RMSE: 44.79
```

图 3.4.3.2

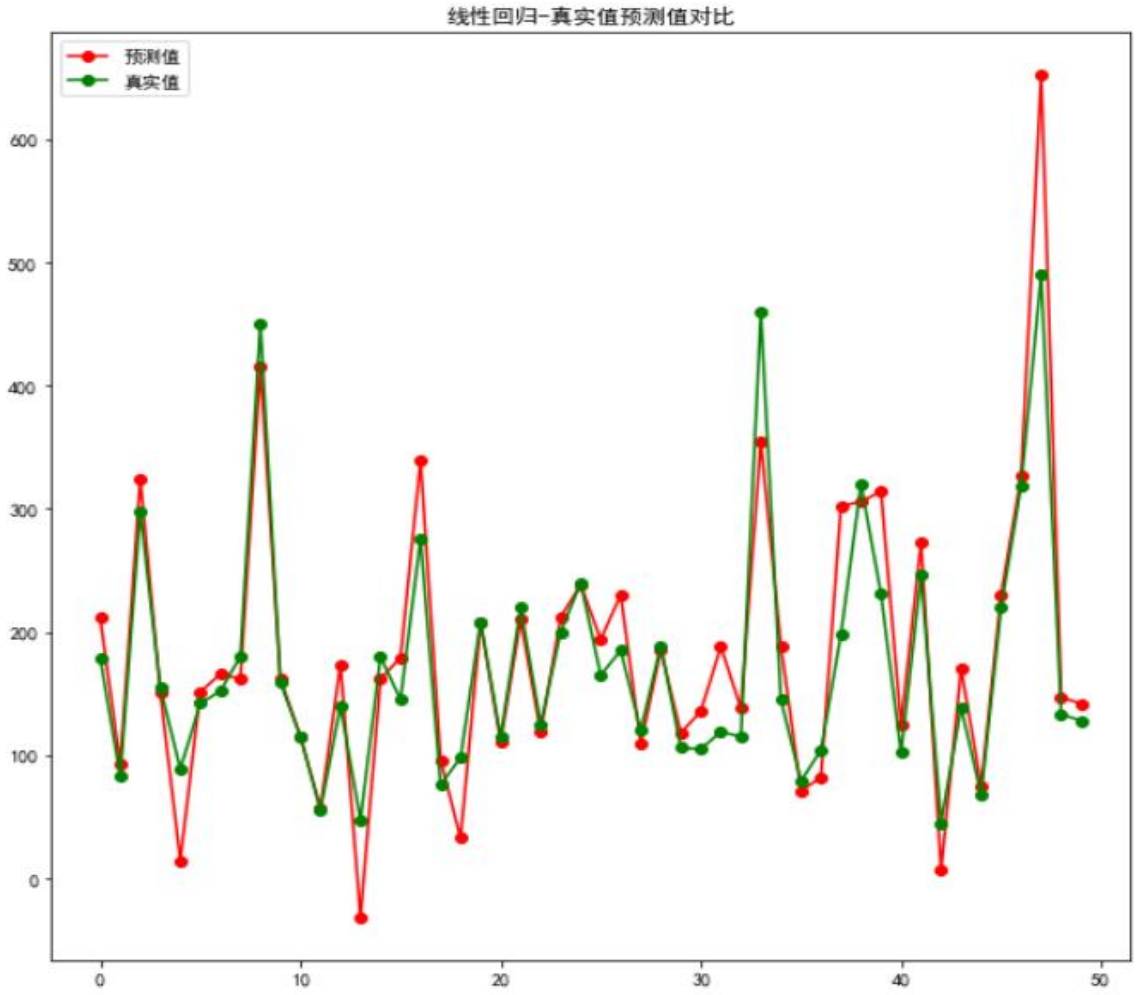

（2） K 近邻模型：

图 3.4.3.3

```
model_knn = KNeighborsRegressor()
model_knn.fit(x_train, y_train)
print("params: ", model_knn.get_params())
print("train score: ", model_knn.score(x_train, y_train))
print("test score: ", model_knn.score(x_test, y_test))
predict_y = evaluation(model_knn)
```

```
params:  {'algorithm': 'auto', 'leaf_size': 30, 'metric': 'minkowski', 'metric_params': None, 'n_jobs': None, 'n_neighbors': 5, 'p': 2, 'wei
ghts': 'uniform'}
train score:  0.8096656409725607
test score:  0.7136126829930158
MAE: 30.13
MSE: 3344.61
RMSE: 57.83
```

图 3.4.3.4

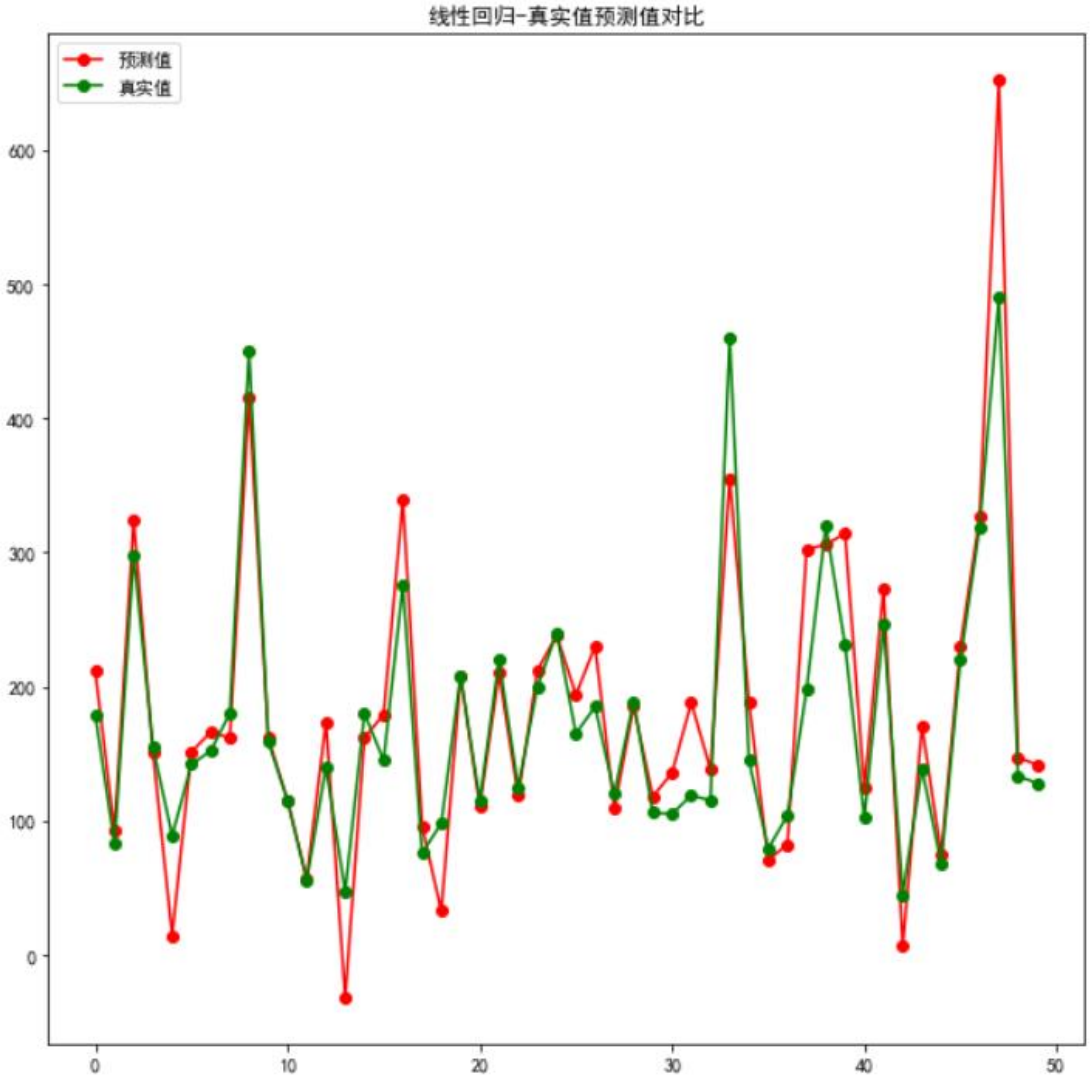

（3） 决策树模型：

图 3.4.3.5

```
model_dtr = DecisionTreeRegressor(max_depth = 5, random_state=30)
model_dtr.fit(x_train, y_train)
print("params: ", model_dtr.get_params())
print("train score: ", model_dtr.score(x_train, y_train))
print("test score: ", model_dtr.score(x_test, y_test))
predict_y = evaluation(model_dtr)
```

```
params:  {'ccp_alpha': 0.0, 'criterion': 'mse', 'max_depth': 5, 'max_features': None, 'max_leaf_nodes': None, 'min_impurity_decreas
e': 0.0, 'min_impurity_split': None, 'min_samples_leaf': 1, 'min_samples_split': 2, 'min_weight_fraction_leaf': 0.0, 'random_stat
e': 30, 'splitter': 'best'}
train score:  0.922834565295732
test score:  0.8370208882993976
MAE: 26.79
MSE: 1903.37
RMSE: 43.63
```

图 3.4.3.6

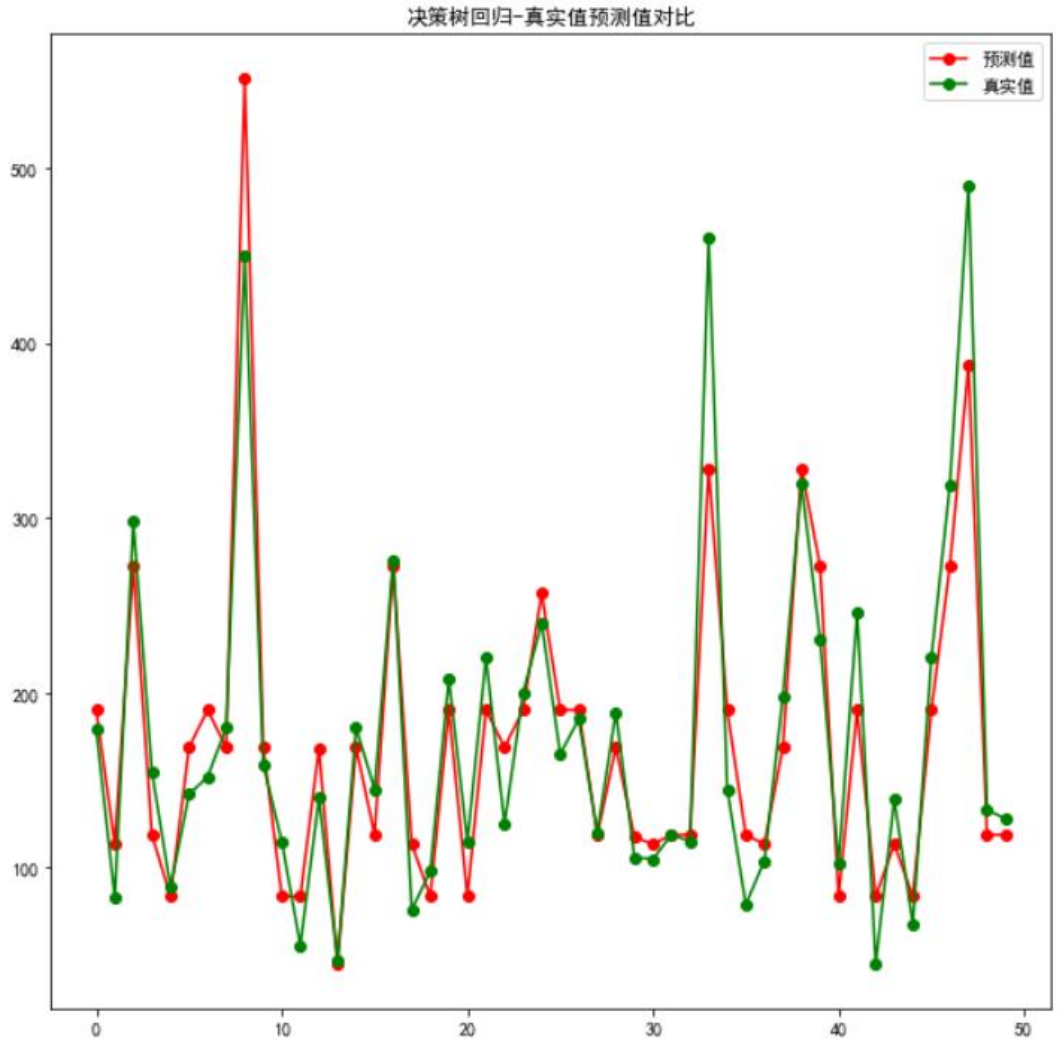

（4） 随机森林模型：

图 3.4.3.7

```
28]: model_rfr = RandomForestRegressor(random_state=30)
     model_rfr.fit(x_train, y_train)
     print("params: ", model_rfr.get_params())
     print("train score: ", model_rfr.score(x_train, y_train))
     print("test score: ", model_rfr.score(x_test, y_test))
     predict_y = evaluation(model_rfr)
```

```
params:  {'bootstrap': True, 'ccp_alpha': 0.0, 'criterion': 'mse', 'max_depth': None, 'max_features': 'auto', 'max_leaf_nodes': None, 'max_s
amples': None, 'min_impurity_decrease': 0.0, 'min_impurity_split': None, 'min_samples_leaf': 1, 'min_samples_split': 2, 'min_weight_fraction
_leaf': 0.0, 'n_estimators': 100, 'n_jobs': None, 'oob_score': False, 'random_state': 30, 'verbose': 0, 'warm_start': False}
train score:  0.989396408811727
test score:  0.9798409633961344
MAE: 5.05
MSE: 235.43
RMSE: 15.34
```

图 3.4.3.8

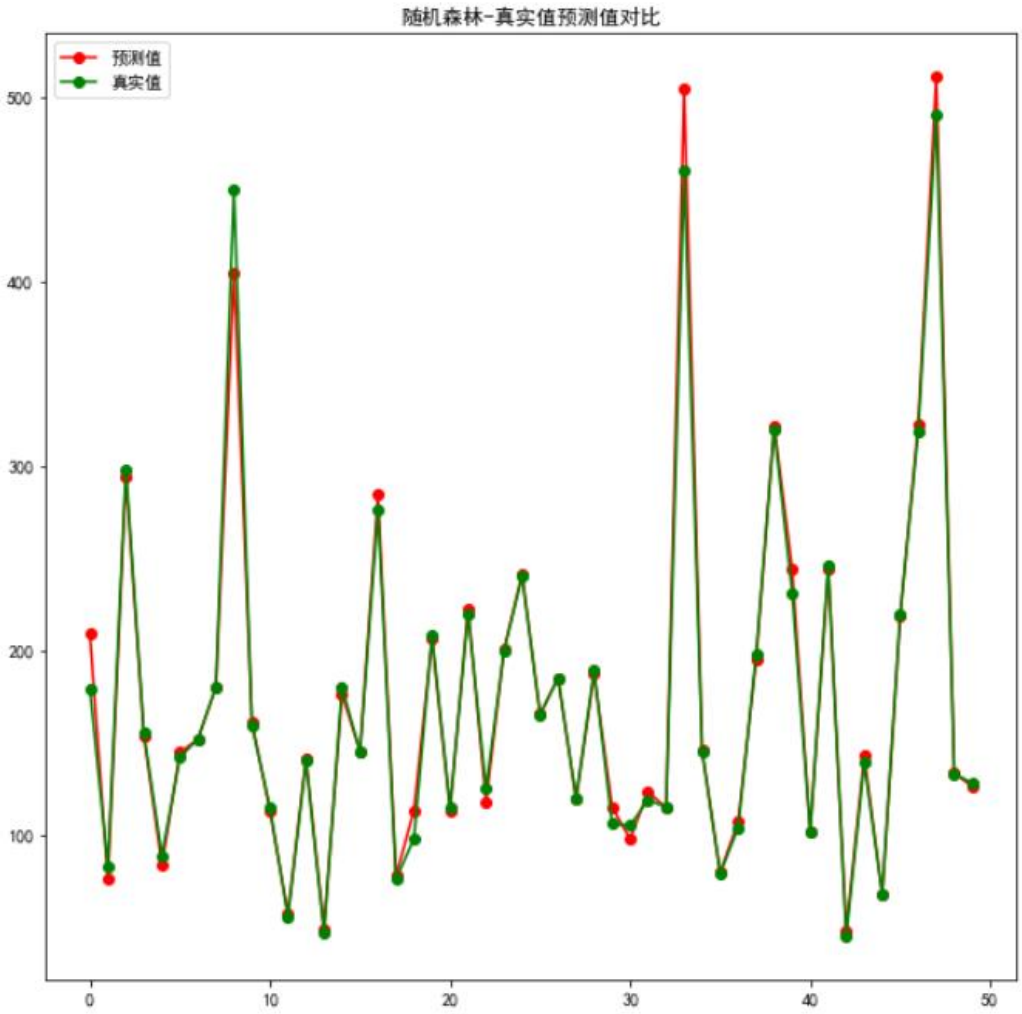

4.实验结果

图 4.1

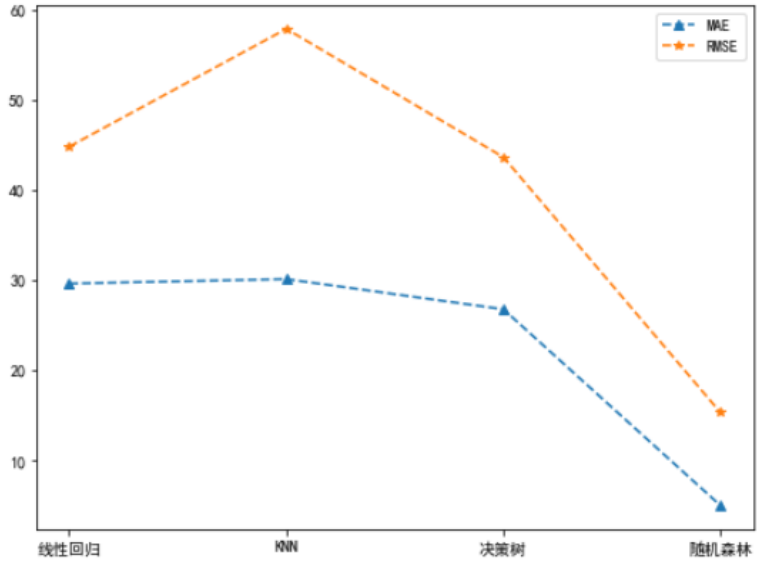

图 4.2

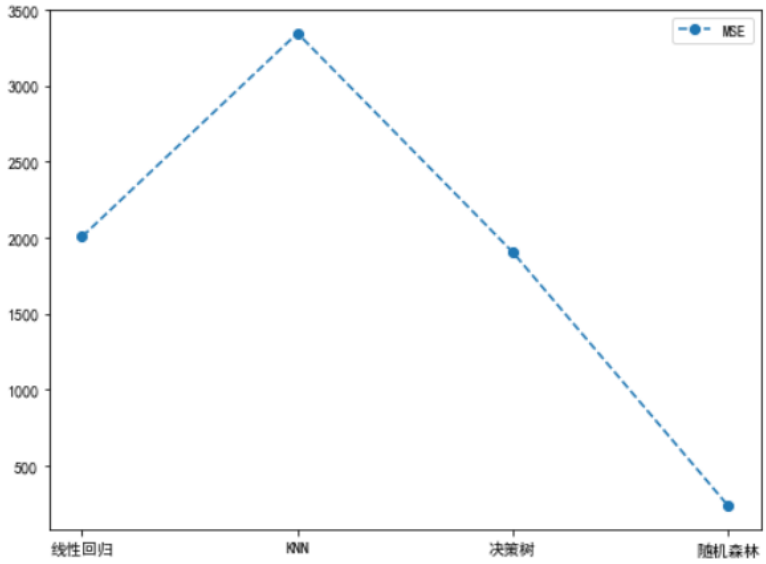

图 4.3

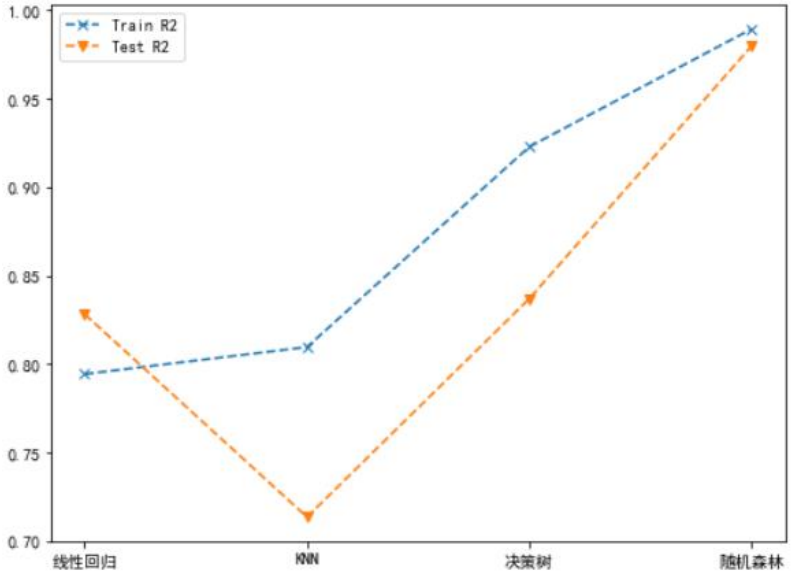

由上述三个图中四个模型所对应的评价指标的比较，可以直接看出随机森林对数据的拟合效果最好，其对二手房房价预测效果最为理想，可以作为预测房价的模型。同样我们可以输出随机森林模型的重要特征进行输出，可以发现是高新区相对于其他地区而言对于总房价的影响是较高的，同样我们可以发现东南朝向地房子价格也比其他朝向地房子价格更高，可能是因为成都地理位置原因，东南朝向光照、通风等条件更好。重要特征如图 4.4 所示。

图 4.4

```
In [48]: feature_important = sorted(
             zip(x_train.columns, map(lambda x:round(x,4), model_rfr.feature_importances_)),
             key=lambda x: x[1],reverse=True)

         for i in range(12):
             print(feature_important[i])

         ('avgPrice', 0.5749)
         ('area', 0.3418)
         ('rooms', 0.0275)
         ('rate', 0.0228)
         ('host', 0.0114)
         ('years', 0.0051)
         ('location_高新', 0.0021)
         ('ele', 0.0015)
         ('hall', 0.0015)
         ('direct_东南', 0.0015)
         ('decorate_其他', 0.0012)
         ('decorate_精装', 0.0011)
```

接下来我们可以将之前相关系数分析出来的重要特征集合与随机森林的前 12 个重要特征取交集，并输出重复的特征，这些特征都是对房价影响程度很大

的因素。重复特征由单位价格、面积、房间数、梯户比、户数、房龄、电梯数、厅数。如图 4.5 所示。

图 4.5

```
In [22]: list1 = []
         list2 = []

         for i in range(12):
             list1.append(feature_important[i][0])

         for i in range(1, 10):
             list2.append(price_corr[i][0])

         cnt = 0
         for i in range(12):
             if list1[i] in list2:
                 print(list1[i])
                 cnt += 1
```

```
avgPrice
area
rooms
rate
host
years
ele
hall
```

5.不足和改进

5.1 不足

1. 数据量较少。仅有四千多条的房屋数据。如果可以获取更多更大范围更加完整的数据,那么建模与预测的结果会更加准确可靠。

2. 特征数较少。数据爬取过程中仅爬取了总价、单位价格、面积、建造时间、楼层、户型、梯户比、装修、朝向、地区等特征，但实际上影响房价的特征远不止这些。还有交通、医疗、教育、物业等等各种特征对房价有着重要的影响，但这些数据有的难以在网站中爬取到，例如有些重要特征并没有在网站中表现出来或是一些私密但重要的特征不予对外公布，或者动态数据等难以爬取。

3. 建模方法较少，评估指标还可更全面。报告提到使用了线性回归、k 近

邻、决策树、随机森林四个模型进行预测,但这只是众多机器学习算法中的少数。同时，我们得到的最优模型可能具有地区的局限性，因为所拟合的数据都为成都市二手房数据，不一定能适用于其它城市的二手房房价预测。

4. 结果分析不够全面透彻，预测变化原因分析可以更加全面和深入。

5.2 改进

1.学习更多相关爬虫知识，能够爬取更多的所需特征。增强自身编程以及各方面学习能力，对相关信息能够进一步提取更多特征。结合 GIS 数据。房价与位置信息高度相关,爬取房源地址后,可以使用 GIS 技术匹配获得相应的位置特征,如距离商业中心的距离、附近交通设施等。这可以为建模提供更加准确的位置信息特征。

2.可以尝试 CatBoost、GBDT、XGBoost 等更加高效的算法与所使用模型进行比较,获得预测性能更强的模型。评估指标方面，可以采用更全面的评估指标,如 MAPE 可以更好衡量回归模型预测误差。还有准确率、AUC、F1 score 等分类指标，更加准确地评估模型的优劣。对于其它城市房价预测，我们可先扩充相应城市数据的训练集，进一步更好的拟合模型。

3.结果分析可以更加全面，预测变化原因分析可以更加全面和深入。结合社会经济因素以及数据特征的关系可以更好解释相关结果,同样可以结合各个学科领域的知识对结果进行分析解释。

从不同渠道获取更丰富的数据,可以整合不同网站爬取的数据,丰富数据量,同样可利用已有数据库中的数据。数据清洗与处理可以更加仔细,避免遗漏重要的异常值与缺失值处理。

6.总结

本次大作业中，运用 python 爬虫技术爬取到所需的数据，利用 python 知识对数据进行处理、可视化分析，最后又使用了四个模型来对二手房价进行预测，根据相关指标挑选出最优模型。总体来说是较为顺利且成功的，能够自身运用通过在课程中所学到的相关 python 知识、编程技术来完成数据分析这一系列流程，在遇到相关问题的时候询问老师同学，或是在网上查询相关解决方法，一步步完善自身的数据分析大作业，最终得出这样一份报告，是十分具有成就感的。课程上学到的知识能够很好地运用到实际中，并且对今后许多课程研究方法或是日常数据的处理或是比赛编程方面都有着很大的帮助。这门课程十分值得学习，老师教得也非常好，一步一步循序渐进，稳扎稳打地一步步学习更多的相关知识，是真的能够学进去而且十分有用的课程。最后，十分感谢老师的关心和指导！