西南財經大學
SOUTHWESTERN UNIVERSITY OF FINANCE AND ECONOMICS

Southwestern University of Finance and Economics

算法交易
课程论文

学年学期：2025 学年第二学期

课程名称：算法交易

论文题目：AlgoTradingAgents 量化交易平台构建

学生学号：42242024、42227089、42227042

学生姓名：郑筱彤、黄译萱、叶巧妍

学　　院：计算机与人工智能学院

年级专业：22 级人工智能（智能金融光华实验班）

2025 年 6 月

AlgoTradingAgents 量化交易平台构建

摘 要：本研究构建多智能体协同交易框架 AlgoTradingAgents，基于 AutoGen 架构，通过 5 个智能体实现股票多维度分析，融合强化学习 PPO 算法进行动态调优。框架模拟真实交易机构架构，形成数据采集、市场分析、风险控制及策略调整的闭环，为金融交易智能化提供创新方案。此外，本研究利用 Akshare 接口构建测试数据集进行了对比实验。结果显示：该框架构建的投资组合在年化收益率、夏普比率等指标上显著优于沪深 300 基准及未调整策略组合，验证了其在量化交易中的有效性与实用性，为智能交易系统工程化应用提供支撑。

关键词：量化交易;算法交易;AI-Agent;投资组合;PPO 算法

一、引言

1.1 研究背景

当前，自动化交易代理在金融市场中的应用日益广泛，且强化学习（RL）技术也被越来越多地融入其中。大语言模型凭借其卓越的非结构化数据处理能力，在金融领域展现出巨大潜力，被应用于宏观经济舆情解析、上市公司财报智能解读和社交媒体情绪分析等任务。实证研究表明，无论是经过微调还是从头训练的金融专用 LLM 在风险溢价识别、市场异动预警等核心金融任务中的表现显著优于传统算法模型。当前技术演进已形成三大方向：基于实时资讯流的交易信号捕捉引擎、依托逻辑推理链的量化策略生成系统，以及融合强化学习反馈机制的多因子挖掘框架，这些技术突破正在重塑投资决策支持系统的技术范式。

然而，现有的系统还存在两个问题：一是单一模型难以融合基本面、情绪、新闻等多源异构数据，且现有风险模型依赖静态指标，缺乏有效的风险管理；二是尽管大预言模型在金融领域的应用取得了显著进展，但多数 LLM 驱动的金融框架侧重于单一任务处理。即使是独立数据收集的多智能体系统，也未能充分模拟真实交易公司中各角色间的协同工作模式。同时部分现有 LLM 智能体框架在通信效率上也存在不足，例如可能出现“电话效应”，导致信息在多轮交互中丢失或失真。

在此背景下，构建能够模拟真实交易机构协作模式的多智能体 LLM 框架成为解决上述挑战的关键。这类框架旨在通过分工明确、协同工作的智能体，实现更全面、可解释的金融决策，提升交易性能。

1.2 研究意义

本研究构建了多智能体协同交易框架 AlgoTradingAgents，该框架基于 AutoGen 架构，接入 deepseek 的 API，通过整合多个智能体，包括基本面分析师、新闻情绪分析师、风险管理者、投资经理和预期调整专家，实现股票的多维度分析，并融合强化学习 PPO 算法进行动态调优，最终输出投资组合建议。

这项研究的意义主要体现在：

1. 模拟了真实交易机构的组织架构，形成了数据采集（通过 AKShare 接口获取真实市场实时数据）、市场分析、风险控制及策略调整的闭环，为金融交易智能化提供了创新且严密的调整方案。这不仅是 LLM 融入风险敏感型强化学习交易代理的扩展，也进一步深化了模拟真实交易公司多代理协作模式的理念。

2. 通过引入 LLM 驱动的风险评估信号和交易信号，并将其与 PPO 融合，框架增强了对金融新闻等替代数据源的整合能力，提升了风险管理水平。同时，多智能体协作机制解决了传统单智能体系统和独立数据收集多智能体框架的不足，实现了更贴近真实交易环境的动态协作。

3. 实验结果显示，本框架构建的投资组合在年化收益率、夏普比率等关键指标上显著优于沪深 300 基准及未调整策略组合。这验证了该框架在量化交易中的有效性与实用性，表明通过风险调整和 PPO 优化能够有效提升组合的盈利能力并实现风险收益再平衡，尽管可能伴随更高的波动性，但策略调整带来的收益增长更具效率。

二、文献综述

量化交易方面的 AI-Agent 一直是金融领域研究的热点。Mostapha Benhenda 等人提出了基于强化学习和大语言模型的风险敏感型交易代理 FinRL-DeepSeek，通过 LLM 从金融新闻中生成的风险评估信号和交易信号，融合 LLM 与 PPO 算法、LLM 与 CPPO 算法进行模型训练，最终在牛市和熊市条件下均表现出了良好性能[1]。Yijia Xiao 等人提出了一个模拟真实交易公司的多代理协作框架 TradingAgents，包括基本面分析师、情绪分析师、新闻分析师、技术分析师、研

究员、交易员和风险经理等多个 LLM 驱动的专业代理，各个代理之间通过结构化通信与自然语言辩论等方式进行协作，最终得到具有全面性和可解释性的投资决策；经过实验，TradingAgents 在累积收益、年化收益和夏普比率、最大回撤等关键指标上表现卓越，在高回报的同时有效控制了风险[2]。

三、研究设计

3.1 系统架构设计

多智能体交易系统通过不同的智能体代理，分解复杂的金融交易任务，实现目标的逐步达成。每个代理具备明确、独立的角色和目标，从而使复杂的交易策略管理变得井井有条。金融交易不仅仅是信号的整合，更涉及多样化的输入和专业的专长整合，类似于现实中的交易公司借助专业团队协作，并做出高风险决策。这种多元化的角色配置和任务分解反映了现代量化交易的复杂性和多样性。

在金融领域，一个典型的交易公司需要处理庞大的数据，包括财务指标、价格走势、交易量、历史表现、经济指标以及新闻情绪。这些数据通过数量分析专家的高级工具和算法进行分析，以识别趋势并预测市场动向。这种组织结构启发了 AlgoTradingAgents 模拟量化交易中 5 个角色：基本面分析师、新闻情绪分析师、风险管理者、投资经理和预期调整专家。每个代理都有特定的名称、角色、目标，并在其功能上具备预定义的背景、技能，并准备相应的数据。AlgoTradingAgents 中 5 个代理均基于 AutoGen 框架构建，调用 Deepseek-v3 的 API 接口。

多智能体交易流程如下：

（1）分析师报告生成：分析师团队负责提供深入的股票分析。基本面分析师综合个股预测、财务报告和行业分析，而新闻情绪分析师则处理财经新闻与市场情绪的影响。

（2）投资经理的初始建议：投资经理根据分析师提供的报告，制定初始投资建议，这些建议反映了当前市场条件和基础分析结果。

（3）风险分析报告：风险分析师评估每个股票的风险参数，生成风险报告，以识别潜在的市场风险。

（4）投资经理的优化建议：投资经理根据风险分析报告调整初始投资计划，优化投资组合以应对风险因素。

（5）预期调整方案专家：根据投资组合和市场预测，提出未来调整方案，

优化投资组合配置以匹配投资者的风险偏好和投资期限。

（6）模拟交易执行并更新投资组合：交易决策被模拟执行，并根据预期调整方案调整投资组合，保持准确性和适应市场变化。

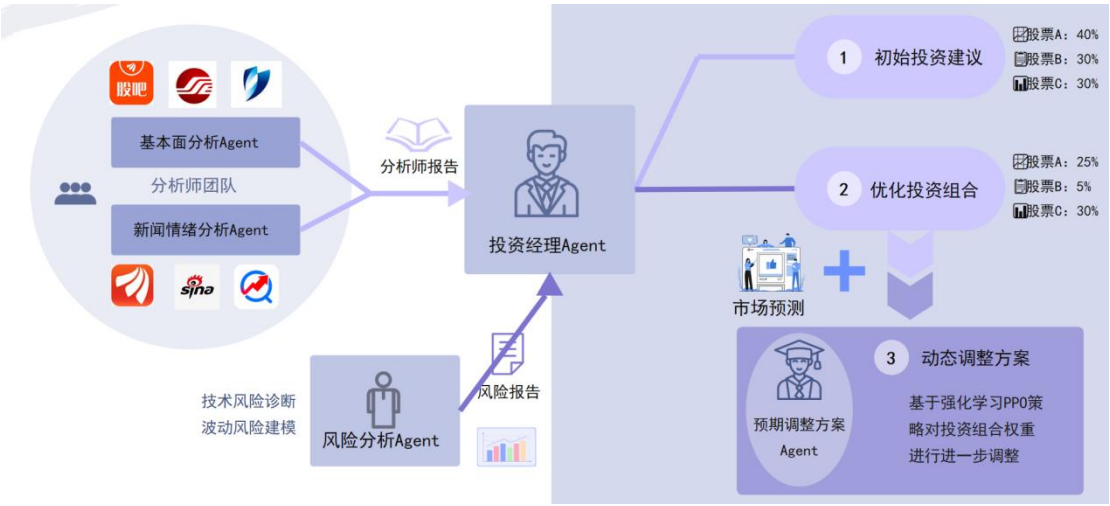

图 1 AlgoTradingAgents 框架图

智能体核心功能如下表：

表 1 智能体核心功能

智能体	核心功能
FundamentalAnalysis Agent	1）企业财务健康度评估（PE/PB/ROE 等核心指标分析）； 2）行业竞争分析（行业排名与头部企业对比）； 3）增长潜力预测（历史财务数据趋势推演）； 4）系统性风险识别（业务模式可持续性判断）。
PublicAnalysisAgent	1）财经新闻情感极性判别（积极/消极/中性）； 2）舆情热度传播路径追踪（媒体/社交平台/专业机构）； 3）突发事件对价格的冲击预测。
RiskAnalysisAgent	1）技术风险诊断：基于移动平均线、RSI、KDJ 等 15+技术指标分析趋势稳定性； 2）波动性风险建模：测算年化波动率、最大回撤等市场异常波动特征； 3）极端风险预警：通过 VaR/CVaR 模型量化尾部风险损失概率； 4）系统性风险评级：综合输出 0-10 分的风险评分及高/中/低三阶风险等级。
ManagerAgent	1）初始决策系统：整合全维度分析师报告（基本面/情绪/行业/技术分析）生成基础投资方案； 2）风险调整系统：根据风险评估结果进行动态优化，实现风险收益再平衡。
ExpectAdjustment Agent	1）市场适应性调仓：基于实时市场环境预测投资组合权重调整； 2）行业轮动策略优化：根据经济周期动态切换行业配置重心； 3）风险收益平衡：在预设风险约束下最大化夏普比率。

3.2 分析师团队

在多智能体交易系统中，分析师团队的报告生成是整个交易周期的关键步骤之一，能够为后续的投资决策提供详尽的数据支持和市场洞察。该团队由多个专门的分析代理组成，每个代理负责特定领域的市场分析。

基本面分析 Agent 负责：

（1）个股分析：该代理聚焦于个股的技术指标及基本面数据，包括股票的估值模型、盈利能力、资本结构、以及现金流等。通过评估公司财务状况与行业平均水准的对比，识别出公司的相对优势或劣势。

（2）公司财务健康度评估：采用财务报告、资产负债表、损益表等财务数据来进行分析，透过各种财务比率如市盈率、市净率、流动比率等来评估企业的财务健康度。

（3）行业趋势与竞争格局分析：分析当前行业的宏观趋势、市场需求变化及竞争态势，探索潜在投资机会。

（4）风险提示：通过评估市场与行业动态，指出可能影响公司财务或市场表现的风险因素。

新闻情绪分析 Agent 负责：

（1）财经新闻摘要：该代理生成财经新闻摘要，识别可能直接影响市场或个股的近期动态事件和行业新闻。

（2）市场情绪评估：采用先进的社交媒体搜索 API 和情绪得分计算算法，从多个信息源收集公众情绪数据，评估市场对新闻事件的反应是积极、消极还是中性。

（3）情感分析：分析公众对个股的情感倾向和关注度，解读社交媒体和新闻文章中提到的关键字、情感分布等信息。

这些报告帮助投资经理制定初始投资策略，使投资组合在配置时考虑宏观和微观层面、历史数据规律和当前市场趋势、金融领域和舆情方面，充分发挥 Agent 数据采集和分析的优势，在保证专业性的同时提高了效率。

3.3 风险分析师

风险分析师应用了多种技术指标来评估股票投资的各种风险。通过移动平均线（MA）、相对强弱指数（RSI）、随机指标（KDJ）和移动平均收敛散度（MACD），

该代理能够识别趋势风险和价格支撑/阻力位的突破风险。这些指标帮助揭示市场的内在动向与潜在转折点，是技术风险评估的核心组成。此外，代理使用年化波动率和最大回撤来衡量波动性风险，并采用价值风险（VaR）和条件价值风险（CVaR）为基础的量化风险指标进行风险度量。技术指标揭示了短期价格行为和市场情绪，而量化指标则更加着眼于投资组合的长期风险暴露及其损失潜能。这些风险指标为理解投资组合在不确定市场条件下可能面临的潜在损失提供了基础，提供了完整而多面的市场视角。

风险分析报告详细阐述了每项投资的风险水平，并提出风险管理建议，如设置止损位、调整仓位大小，以及定期审查投资策略。投资经理根据这些反馈，调整投资组合以确保其符合公司或个人的风险限额和投资目标。

3.4 投资经理

投资经理代理（ManagerAgent）在 AlgoTradingAgents 系统中有两大核心功能：根据分析师团队的报告生成初始投资组合，以及根据风险分析师的评估优化投资决策。

投资经理代理在制定初始投资组合时，综合考虑来自分析师团队的多方面报告。首先，它审阅市场走势与趋势预测，确保投资策略适应当前市场环境。接下来，它检查公司财务状况，以识别具有强健财务表现的投资标的。新闻情绪分析师提供的市场情绪和舆论影响分析，则帮助经理合并市场反应和公众情绪数据，行业趋势和竞争格局研究为投资经理提供了宏观视角。此外，通过技术指标和交易信号，支持投资决策的技术层面。投资经理评估各分析师间建议的一致性与分歧，然后综合这些信息，制定买入、卖出或持有的交易行动。同时它设定初步的投资组合权重分配，设定合理的目标价位与止损价，确保投资组合与公司的收益目标及风险容忍度保持一致。

在生成初步投资决策后，投资经理利用风险分析师提供的风险报告对投资组合进行优化。代理细致分析每只股票的风险等级和具体风险点。高风险股票通常需要降低权重或从投资组合中剔除，而中风险股票需设定严格的止损来限制潜在损失。低风险股票则可以作为稳定的投资组合成分，适度增加其权重。通过调整股票的权重和动作（例如从买入转变为持有），投资经理代理确保投资组合的分散化和均衡的风险暴露。此外，投资经理代理会根据不同风险等级调整目标价位

和止损价，以控制整体风险。

因整合多支股票的分析师报告，易超出大模型输入限制，我们对数据进行了结构化整理。首先对基本面分析报告进行价值因子提取，包括 PE/PB/ROE 等核心估值指标和企业竞争优势评估、行业景气度、竞争格局和成长性预测等；同步处理情绪分析报告中的情绪极性值、舆情热度和机构关注度指数。分析师报告统一整合为 StockAnalysisReport 数据结构作为初始决策构建输入。输出报告则进一步精炼信息，整理为 TradingDecision 数据结构，作为调整投资方案构建的输入。

3.5 预期调整建议专家

预期调整建议专家负责实现组合动态优化，代理利用强化学习 PPO 算法与大语言模型（LLM）结合的方式，构建起“数据驱动+智能决策+专业解释“架构。主要流程为：（1）将当前的投资组合信息（包括持仓权重、个股风险收益特征、市场情绪、行业分布）转化为状态向量，构建 PPO 状态空间；（2）通过动作缩放、行业适配性和基础比例对投资组合进行约束，在约束条件下利用 PPO 算法生成最优调整动作；（3）模拟投资组合收益，计算奖励，评估方案优劣，根据评估结果进行调整和再评估循环；（4）将 PPO 调整结果传入 LLM，转化为可解释的专业投资建议。经过上述步骤，最终即可得到具备科学性和可解释性的投资方案。

四、实验分析

4.1 数据准备

AlgoTradingAgents 数据采集层调用 AKShare 接口，获取了如下数据：股票基本信息、历史行情数据、财务指标、个股所在行业数据、研究报告、财经新闻、行业新闻、市场情绪数据、热门股票排名、行业关注度、个股关注度、个股参与意愿、以及各项技术指标。技术指标通过股票历史数据计算获得，包含了移动平均线、MACD、RSI、KDJ、布林带和调用 edheck_risk_kit.py 库计算获得的年化收益率、年化波动率、夏普比率、最大回撤、复合收益率、半标准差、偏度、峰度、历史风险价值、高斯风险价值、历史条件风险价值。结构化和非结构化数据共包含 28 项。

以上数据均通过 AsyncDataCollector 类获取，为提高数据采集效率，我们使用异步的方式构建，可同时获取多只股票相关的信息。

除此之外，当出现报告缺失时，根据行业相似度等方式生成替代数据，保证输入数据的完整性，提高系统的鲁棒性。

4.2 输出结果

我们模仿沪深 300 指数的行业和市值分布，以分层的形式随机选取出了股票组合。按照预设不同的行业权重比例（金融 20%、消费 20%、科技 20%、医药 13%、工业 13%、能源 13%）来确定每个行业的股票配置，同时在每个行业内部，将股票分为大盘、中盘、小盘，尝试从不同的市值层级中选取股票，最终选取的股票投资组合如下，其中大盘股占 73%，中盘股占 27%：

表 2 实验选择的投资组合股票

行业 股票			
银行	工商银行(大盘)	招商银行(大盘)	宁波银行(中盘)
消费	贵州茅台(大盘)	伊利股份(中盘)	海天味业(中盘)
科技	腾讯控股(大盘)	恒瑞医药(中盘)	海康威视(中盘)
医药	迈瑞医疗(大盘)	药明康德(中盘)	
工业	三一重工(大盘)	中国中车(大盘)	
能源	中国石油(大盘)	中国神华(大盘)	

按照该投资组合选取思路，可以有效避免投资组合过于集中在少数行业，降低特定行业周期性波动带来的风险，提升组合的行业分散性。同时分层策略考虑了市值因子对股票表现的影响，可以更好地捕捉市场多样性，从而更科学合理地与沪深 300 市场基准进行对比。

经过 AlgoTradingAgents 模拟量化交易后，得出的初始、风险调整、PPO 调整后的投资组合如下：

表 3 投资组合权重

	贵州茅台	工商银行	招商银行	恒瑞医药	迈瑞医疗	药明康德	宁波银行	海康威视	三一重工	中国中车	伊利股份	海天味业	腾讯控股	中国石油	中国神华
原始权	8%	10%	7%	12%	6%	10%	7%	9%	6%	3%	不买入	不买入	不买入	不买入	不买入

重															
风险调整权重	9%	9%	6%	10%	卖出	8%	5%	8%	卖出	3%	不买入	不买入	不买入	不买入	不买入
PPO调整权重	11%	11%	7%	10%	5%	13%	11%	12%	11%	7%	不买入	不买入	不买入	不买入	不买入

根据系统给出的投资组合权重，我们进行模拟买入决策，将各个权重之间结果在多个数据指标下进行对比，同时引入沪深 300 基准，结果如下：

	年化收益率	年化波动率	夏普比率	索提诺比率	最大回撤	年化超额收益率	超额收益年化波动率	信息比率	相对基准月胜率	超额收益最大回撤	偏度	峰度	VaR_5%	CVaR_5%	累计收益	年化累计收益
原始	8.53%	13.75%	0.4455	0.665595	-11.67%	5.13%	9.12%	0.5628	0.5600	-13.17%	0.4200	10.1979	-1.06%	-1.76%	17.02%	9.55%
风险调整	11.83%	17.53%	0.5541	0.861505	-13.26%	8.93%	9.51%	0.9393	0.6400	-9.75%	0.5484	8.7379	-1.33%	-2.21%	23.96%	13.55%
PPO调整	12.16%	17.13%	0.5801	0.840107	-13.81%	9.21%	9.18%	1.0034	0.6000	-11.10%	0.2657	10.5354	-1.31%	-2.23%	24.65%	13.81%
沪深300基准	2.04%	18.42%	0.0382	0.056325	-21.42%	0.00%	0.00%	nan	0.0000	0.00%	0.5759	12.8578	-1.30%	-2.38%	3.95%	3.77%

图 2 结果展示

实验模拟了中等型投资偏好、长期（1 年以上）投资期限的情况，根据为期两年的回测数据，通过对原始组合、风险调整组合、PPO 调整组合及沪深 300 基准的全面绩效评估，我们发现优化策略在收益增强和风险控制方面都取得较好效果。其中，经过风险 agent 调整后，其年化收益率有所提升，在兼顾保守性的同时获取更大收益；再次通过 PPO 调整后，组合表现则更为突出，年化收益率达 12.16%，超额收益率、夏普比率、所提诺比率均表现明显。

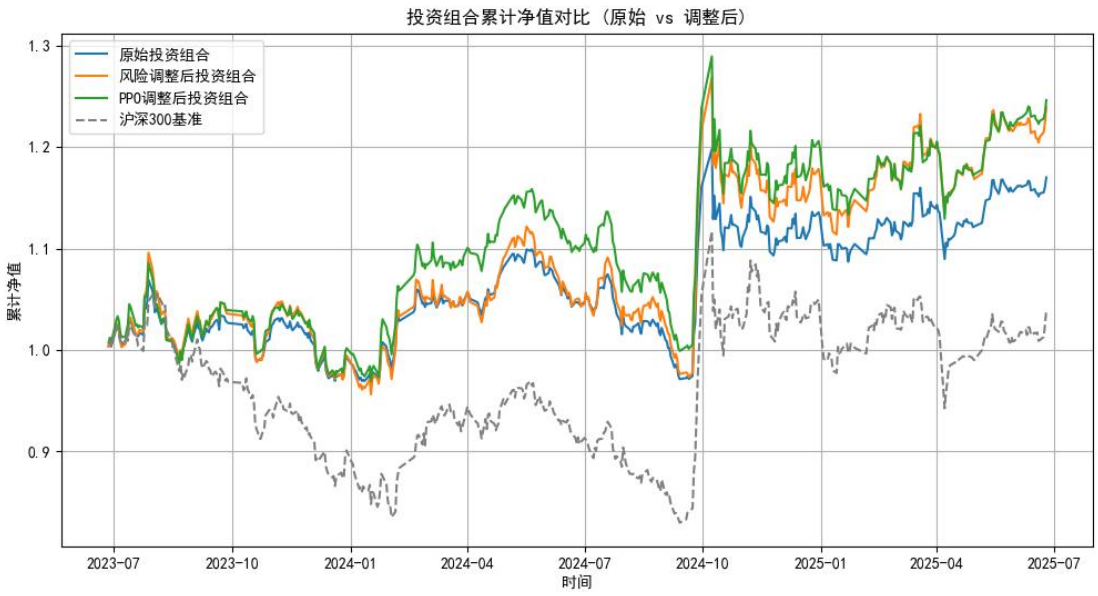

图 3 投资组合累计净值对比

从整体收益来看，图 3 清晰展示了风险调整和 PPO 调整后组合的累计净值明显高于原始组合与市场基准。该实验表明经过 AlgoTradingAgents 对初始投资建议进行二次优化，确实能够有效提升组合的盈利能力。

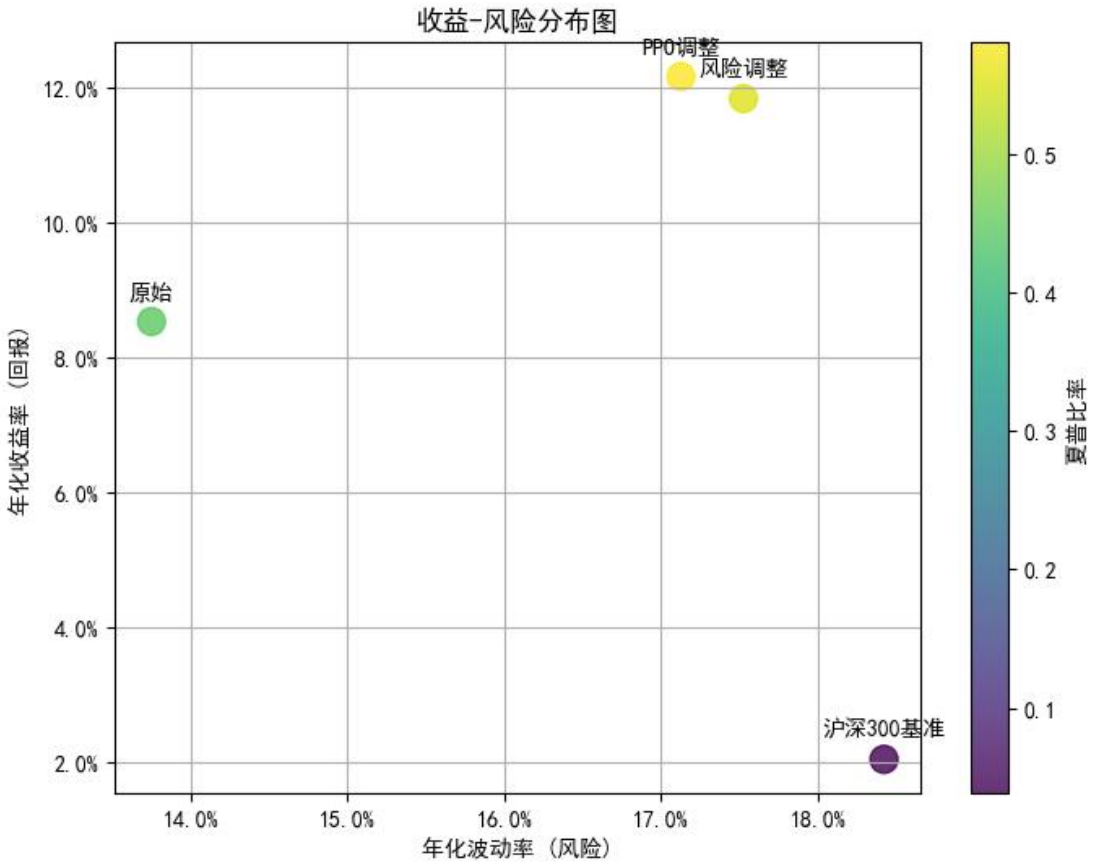

图 4 收益-风险散点图

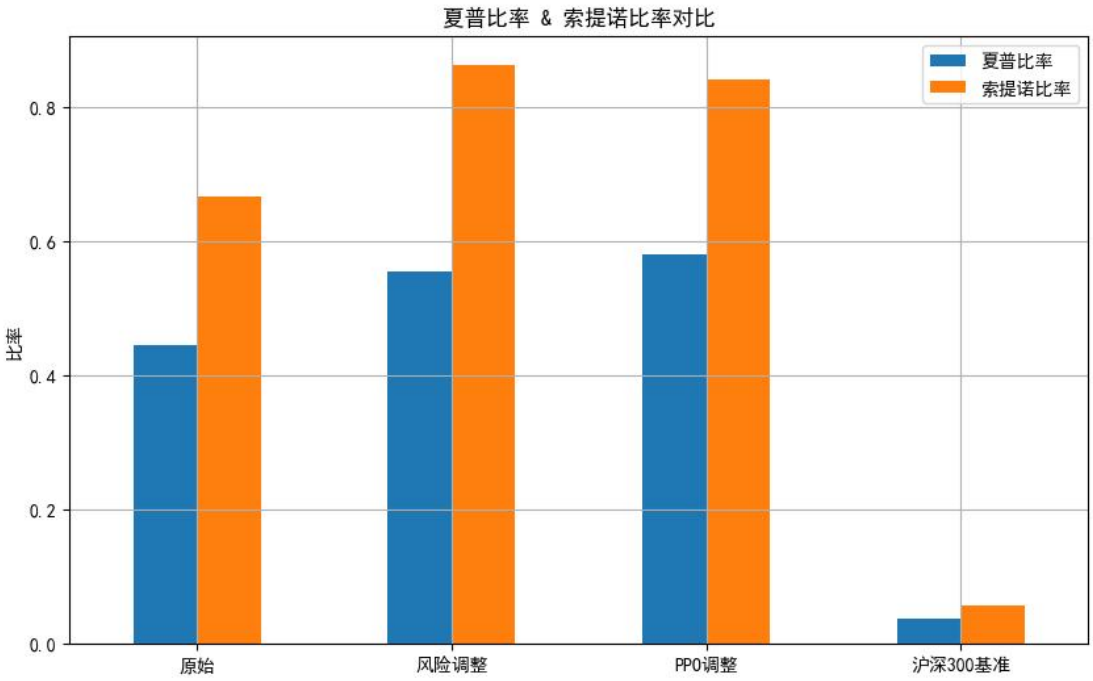

图 5 夏普比率和所提诺比率对比图

从收益与风险的角度看，经过风险调整和 PPO 调整后，组合通过承担更高风险换取更高的年化回报；但同时，风险调整和 PPO 调整后的组合夏普比率更高，尽管增加了波动，但策略调整所带来的收益增长更具效率，成功实现了风险收益再平衡的目标。

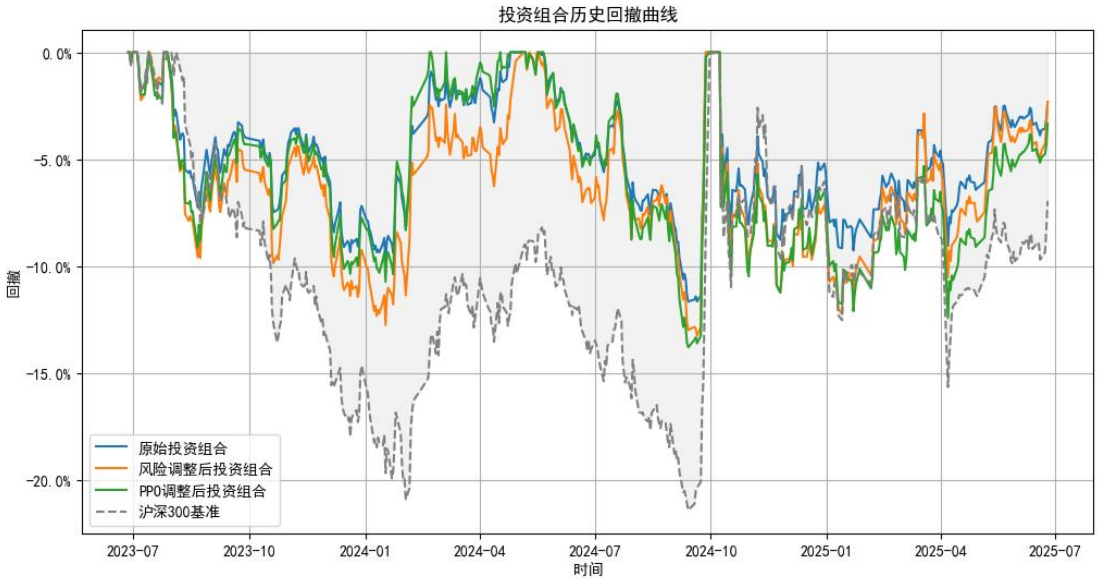

图 6 历史回撤曲线图

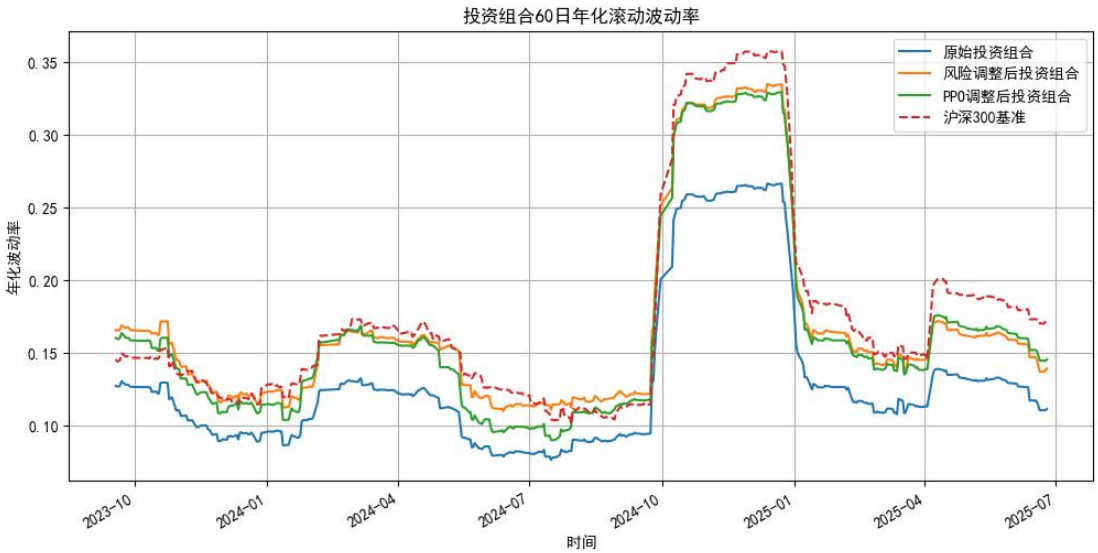

图 7 年化滚动波动率曲线

从风险控制层面看，所有投资组合的抗风险能力均显著优于市场基准，说明系统在选股和构建层面考虑收益的同时，也综合了基础风控的有效性。值得注意的是，组合经过两次调整后虽然获得了更高收益，但其最大回撤和滚动波动率也相应提高，这表明 agents 更侧重于优化收益风险比，实行在预设风险约束下最大化夏普比率的目标。

4.3 网页展示

为了更方便地实现应用，我们搭建了一个网页，以下进行网页实操展示。

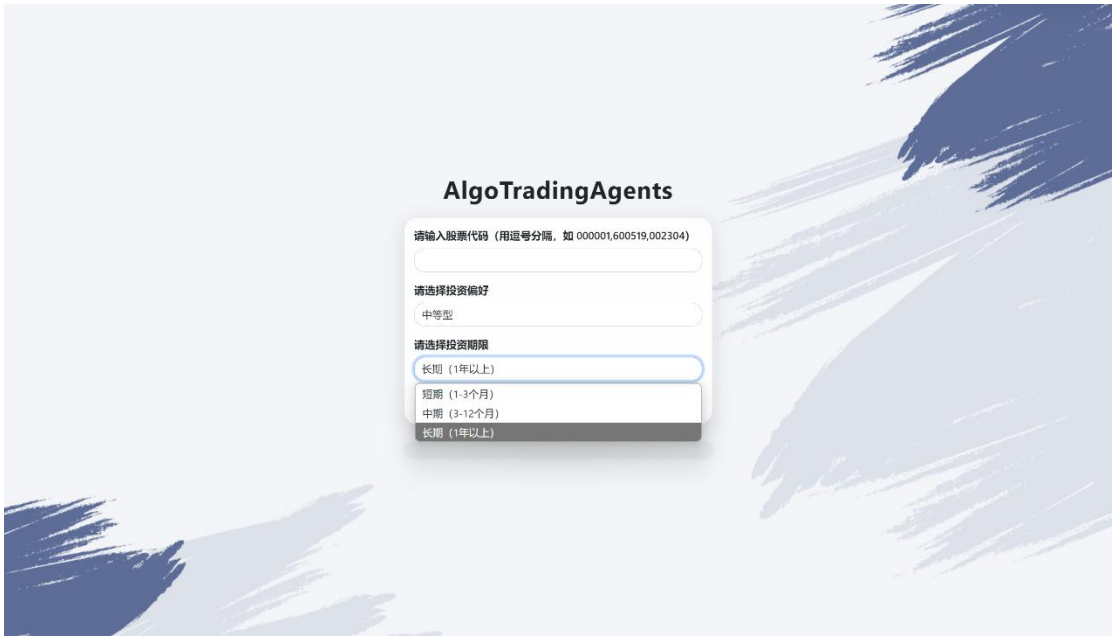

图 8 网页实操展示 I

进入网页，用户首先需要设定自己地投资偏好、投资期限，并给出备选的股票代码，后续系统将会考虑到用户的输入信息，个性化地构建投资决策。

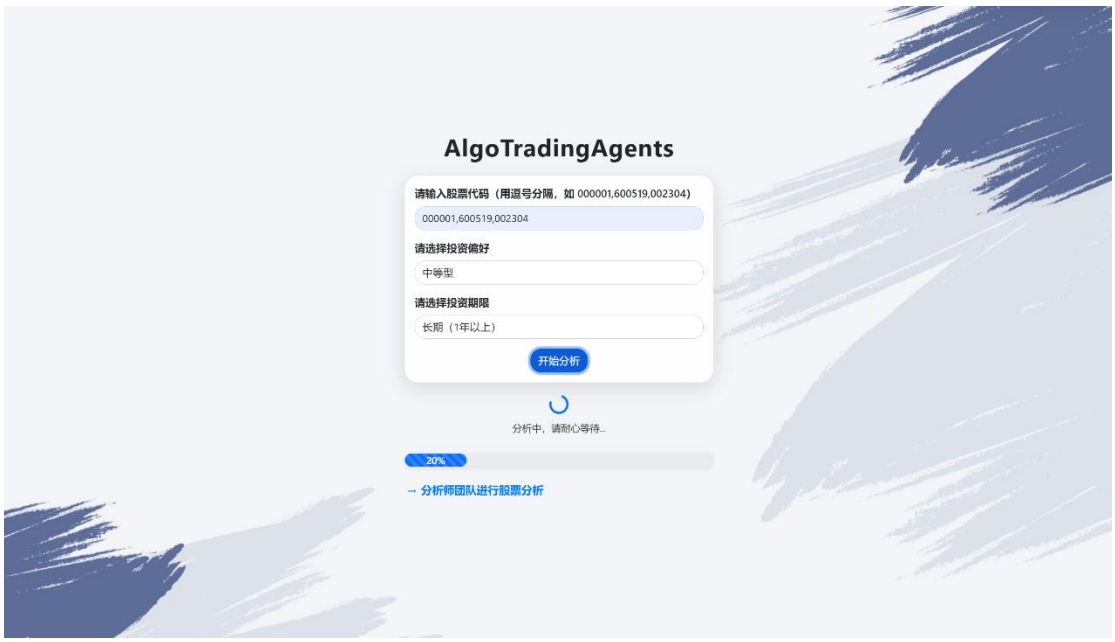

图 9 网页实操展示 II

用户完成信息填写后，点击开始分析，后台即开始进行股票分析以及投资组合构建，整个流程一共分为：“分析师团队进行股票分析”、“投资经理制定初始投资建议”、“风险分析师进行风险分析”、“投资经理根据风险报告优化投资建议”、“生成投资组合预期调整方案”这 5 个步骤，网页进度条将实时显示当前进度。

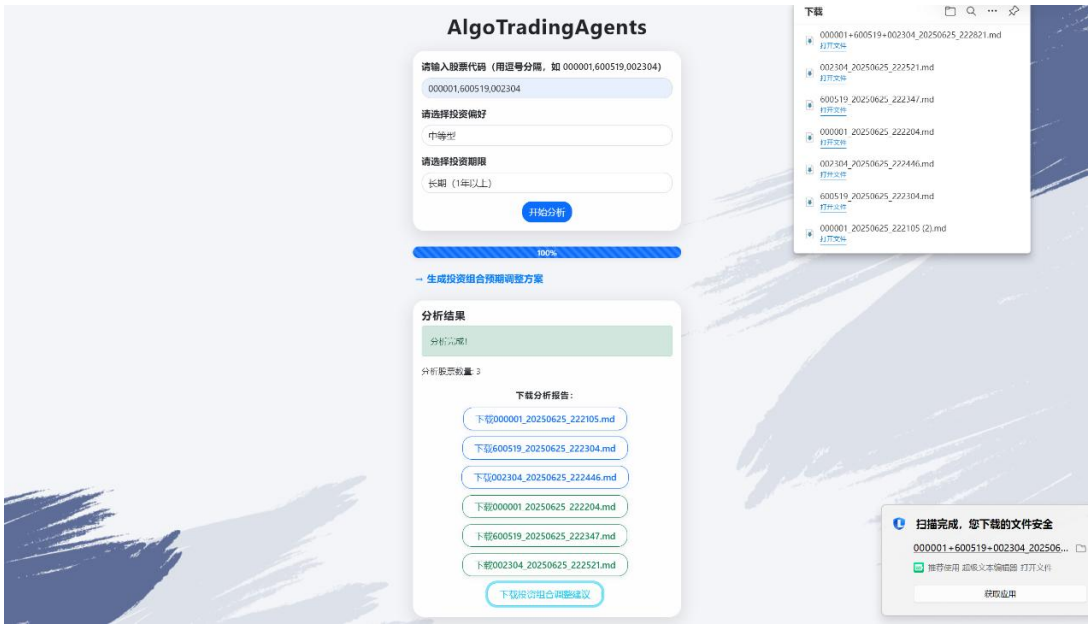

图 10 网页实操展示III

流程完成后，可以在网页上下载每支股票的基本面分析报告、新闻分析报告，以及最终的投资组合调配建议报告（均为 markdown 格式）。以下是一个示例。

1. 行业配置分析表格

股票代码	行业	当前权重	适配性调整系数	建议权重范围
000001	金融(银行)	26.41%	0.8	15%-25%
600519	消费(白酒)	41.88%	1.2	30%-40%
002304	消费(白酒)	31.71%	1.2	25%-35%

适配性规则说明:

- 金融行业在上涨市场中通常表现稳健但弹性不足，调整系数0.8
- 消费行业（特别是白酒）在上涨市场中有超额收益潜力，调整系数1.2
- 当前白酒行业合计权重73.59%显著高于建议范围（55%-75%上限），需注意行业集中风险

2. 风险指标对比列表

指标	当前组合	行业均衡基准	偏离度
波动率	28%	22%	+27%
夏普比率	1.15	1.30	-11.5%
行业集中度	73.6%	≤60%	+22.7%
最大回撤	35%	28%	+25%

关键发现:

- 白酒行业双龙头配置导致行业风险敞口过大
- 600519单一个股权重41.88%突破30%风控阈值
- 组合波动率比基准高6个百分点

3. 操作建议段落

再平衡建议（立即执行）:

1. **强制减仓**: 将600519权重从41.88%降至30%（卖出28.4%持仓）
2. **行业再平衡**:
   - 白酒行业总权重从73.6%调降至60%（需卖出17.3%白酒持仓）
   - 将银行股权重从26.4%提升至35%（加仓8.6%）
3. **替代性配置**:
   - 将减持资金中的10%转配科技ETF（如515000）以提升组合弹性
   - 保留5%现金应对可能的短期波动

后续监控:

- 触发条件: 任一行业权重偏离目标±10%或单一个股突破25%
- 再平衡频率: 季度定期调整+阈值触发机制
- 重点观察白酒行业估值分位数（当前80%分位需警惕）

预期调整效果:

- 波动率将从28%降至24%左右
- 夏普比率有望提升至1.25+
- 行业集中度回归安全区间（白酒≤60%+银行35%+科技5%）

> 注: 建议在3个交易日内分批完成调仓以降低冲击成本，特别注意600519的流动性风险（日成交额需 > 5亿元时操作）

图 11 导出 markdown 报告示例

五、结论与展望

5.1 结论

本研究构建并测试了多智能体协同交易框架 AlgoTradingAgents，该框架通过 5 个智能体（基本面分析师、新闻情绪分析师、风险管理者、投资经理和预期调整专家）的协同决策机制，实现了对股票市场多维度、深层次的分析以及初步调优，再融合强化学习中的 PPO 算法进行进一步动态调优。实验结果令人鼓舞，清晰地展示了构建的投资组合在年化收益率和夏普比率等核心绩效指标上，均显著优于传统的沪深 300 基准以及未经优化的原始策略组合。这验证了 AlgoTradingAgents 在复杂量化交易环境中的有效性，其核心贡献在于成功实现了投资组合的风险收益再平衡，并且在系统层面的选股和构建阶段便综合考虑了风险控制，使得所有生成的投资组合都展现出优于市场基准的抗风险能力。

5.2 展望

尽管 AlgoTradingAgents 框架在提升投资组合绩效方面取得了显著进展，但也存在一些现存的问题和未来的改进方向。当前，尽管经过风险调整和 PPO 优化后的组合实现了更高的收益，但其最大回撤和滚动波动率等风险水平也随之增加，这表明在追求更高的夏普比率和收益风险比的同时，对绝对风险的控制仍有提升空间。此外，本框架目前主要基于 A 股市场数据进行验证，且在实验验证阶段未能充分覆盖小盘股数据，这限制了其在不同市场环境和资产规模上的通用性和适应性。为了解决这些问题，未来的研究将着力于多方面提升框架的性能和稳健性。可以引入更先进且灵活的风险管理模型与算法，例如集成动态止损策略、条件风险价值（CVaR）优化或多目标优化方法，以在保持高收益效率的同时，更有效地限制极端风险。同时，我们将积极探索将框架应用于更广泛的金融市场（如港股、美股）或不同资产类别（如商品、债券），并考虑引入更丰富的异构数据源和更高级的智能体间协作机制，以进一步提升框架的泛化能力和适应复杂市场环境的鲁棒性。

参考文献

[1] Benhenda, M., 2025. FinRL-DeepSeek: LLM-Infused Risk-Sensitive Reinforcement Learning for Trading Agents. arXiv preprint arXiv:2502.07393.

[2] Xiao, Y., Sun, E., Luo, D. and Wang, W., 2025. Trading Agents: Multi-Agents LLM Financial Trading Framework, AAAI.